

长安大学毕业设计（论文）开题报告表

课题名称	基于深度强化学习的车联网计算卸载研究				
课题来源	自选项目	课题类型	工程设计	指导教师	刘树美
学生姓名	王钰博	学 号	2022901300	专 业	计算机科学与技术 (卓越工程师)

一、课题的意义

随着自动驾驶、增强现实导航、车路协同等智能交通应用的快速发展，车联网系统面临计算密集、时延敏感、资源动态变化等多重挑战。车辆本地算力有限，难以满足高实时性任务的需求，而移动边缘计算虽然提供了低时延计算能力，但其资源受多车共享影响呈现高度动态性，且车辆高速移动导致无线信道快速变化，使传统基于局部信息的贪婪卸载策略难以实现全局最优。

预测辅助技术为解决上述问题提供了新的思路。LSTM 预测引擎能够实时同步物理车辆的状态、网络环境和资源信息，并通过云端的高算力实现全局视角的预测与决策。Zheng 等人提出的辅助预测赋能 IoV 卸载框架表明，预测辅助可显著提升任务卸载策略的前瞻性与稳定性，在系统成本与收敛速度方面优于传统方法。

从学术价值看，本课题将深度强化学习（A3C）、预测辅助、车联网边缘计算进行融合，探索动态环境下的智能卸载策略，为 IoV 场景中的资源调度、网络优化提供新的理论模型与算法框架。从应用价值看，该研究可提升车联网系统的任务执行效率、降低能耗与时延，为智能驾驶、智慧交通基础设施建设提供可落地的技术支撑。

二、国内外发展状况

车联网（Internet of Vehicles, IoV）作为智能交通系统的重要组成部分，近年来在自动驾驶、增强现实导航、车路协同等场景中展现出广泛应用前景。然而，车辆本地计算能力有限、无线信道高度动态、边缘服务器资源受多车共享影响等问题，使得任务卸载策略的设计成为 IoV 研究的核心挑战之一。围绕这一问题，国内外学者从移动边缘计算（MEC）、深度强化学习（DRL）和预测辅助等多个方向展开了系统研究，形成了较为丰富的技术体系。

（一）国内发展状况

在国内研究方面，MEC 任务卸载与资源优化是备受关注的方向。Chen 等人提出了两阶段元学习方法，以降低边缘资源消耗并提升卸载效率，在动态环境中表现出良好的适应性^[1]。Alahmadi 等人进一步研究了功耗、传播时延与排队时延的联合优化问题，提出了高效的任务分配策略^[2]。Zhang 等人针对 FiWi（光纤-无线融合）增强的车联网场景，构建了任务卸载优化模型，以最小化任务执行时延为目标，提出了有效的资源调度方案^[3]。Lee 等人则从雾计算角度出发，设计了启发式资源分配算法，用于降低车辆应用的服务时延^[4]。随着深度强化学习的发展，Dai 等人提出异步深度 Q-learning 算法用于 MEC 车联网中的数据驱动卸载决策^[5]，Du 等人则在 TVWS 频段下研究了双侧成本最小化问题，兼顾车辆终端与 MEC 服务器的成本优化^[6]。此外，Zhan 等人利用 DRL 解决 MEC 场景中的长期成本优化问题，证明了 DRL 在高维状态空间中的有效性^[6]；Zhu 等人将任务卸载建模为 Stackelberg 博弈，并使用 DRL 实现车辆与 MEC 服务器的收益最大化^[9]。这些研究为 IoV 场景下的任务卸载提供了坚实的理论基础。

随着数字孪生技术的兴起，国内学者开始探索 DT 在 IoV 中的应用潜力。DT 能够通过虚拟模型实时同步车辆状态、网络环境与资源信息，为任务卸载提供全局视角与预测能力。此外，国内研究还将 DT 与 6G-IoV、SAGIN（空天地一体化网络）、ISAC（通信感知一体

化)等新型网络架构结合,进一步拓展了 DT 在智能交通中的应用边界。

(二) 国外发展状况

在车联网任务卸载与资源管理方面,国外研究最早多从移动边缘计算视角出发,关注如何在车辆—路侧—云之间进行协同计算与资源优化分配。典型工作中,学者们将车联网视作一种特殊的移动边缘计算场景,综合考虑车辆高速移动、无线信道时变性以及边缘服务器负载不均等因素,构建联合任务卸载与无线/计算资源分配模型,并通过凸优化、博弈论或启发式算法实现时延与能耗的折中优化,为后续智能化决策方法奠定了基础^{[9][10]}。

随着深度学习与强化学习的发展,深度强化学习(DRL)逐渐成为解决车联网任务卸载决策问题的主流技术之一。相关研究通常将任务卸载建模为马尔可夫决策过程(MDP),以车辆状态、信道状态、边缘服务器负载等为环境状态,以卸载比例、目标边缘节点选择、计算资源分配等为动作,通过深度 Q 网络(DQN)、深度确定性策略梯度(DDPG)、多智能体强化学习等方法,学习在复杂动态环境下的近似最优卸载策略。例如,有研究针对车载边缘计算中任务到达随机、RSU 负载差异显著的问题,设计了深度强化学习驱动的任务调度与卸载策略,在保证时延约束的同时有效降低系统能耗。在此基础上,一些工作进一步将资源管理建模为博弈过程,引入深度强化学习求解动态资源竞争与收益分配问题,从而提升系统整体效用与公平性^{[11][12]}。

近年来,数字孪生(Digital Twin, DT)理念被引入车联网与边缘计算场景,为任务卸载策略设计提供了新的思路。相关研究通过在云或边缘侧构建车辆、道路环境及通信网络的数字孪生体,对车辆轨迹、信道状态、任务到达过程等进行建模与预测,从而在“虚拟空间”中提前评估不同卸载策略的性能,并将孪生环境与强化学习、博弈优化等方法结合,实现对真实车联网环境的“仿真—决策—反馈”闭环优化。一些工作提出数字孪生驱动的车载边缘计算架构,通过孪生模型对车辆移动性和网络状态进行预测,辅助任务预卸载与资源预留,显著降低了任务违约率与服务中断概率^[13]。也有研究将 DT 与 DRL 结合,在孪生环境中进行大规模策略训练,再将训练好的策略迁移到真实车联网系统中,以减少在线探索带来的时延与安全风险^[14]。

总体来看,国外在 MEC、DRL 与 DT 三条技术路线下形成了较为成熟的研究体系:从理论建模到智能决策,再到虚实融合的系统架构,研究不断向更高的智能化、更强的鲁棒性和更低的时延目标演进。这些成果为我国车联网任务卸载研究提供了重要参考,也为未来构建高可靠、低时延的智能交通系统奠定了坚实基础。

综上所述,国内外研究虽在 MEC 任务卸载、DRL 决策优化和 DT 建模方面取得了显著进展,但仍存在以下不足:一是多数卸载策略依赖局部信息,难以应对 MEC 资源的高度动态性;二是无线信道与任务到达率的随机性未被充分建模,预测能力不足;三是 DRL 在 IoV 中的状态空间巨大,训练效率与稳定性仍需提升;四是 DT 在 IoV 中的应用多集中于交通仿真,面向任务卸载的 DT 预测与决策框架仍不完善。因此,构建一个融合 DT 全局信息、状态预测模块与 A3C 智能决策的卸载框架,成为当前车联网研究的重要方向。

三、研究内容

本课题拟构建一个预测辅助赋能的车联网任务卸载系统,结合深度强化学习实现动态环境下的智能卸载决策,主要研究内容如下:

(一) 车联网仿真系统模型构建

1. 构建车辆—RSU/MEC—云服务器三层架构
2. 建立 V2I/V2C 信道模型,考虑大尺度衰落、小尺度衰落与车辆高速移动
3. 建立本地、MEC、云端计算模型,量化时延与能耗
4. 构建任务队列模型与系统状态描述

(二) 基于深度学习的状态预测模块

1. 使用 LSTM/RNN 预测未来任务到达率
2. 使用历史吞吐量数据预测未来无线链路质量
3. 缓解信道不稳定与任务突发带来的决策不确定性

(三) 基于 A3C 的智能卸载算法设计

1. 将卸载问题建模为 MDP
2. 定义状态空间（队列状态、预测吞吐量、剩余能量等）
3. 定义动作空间（本地/MEC/云端）
4. 设计奖励函数（时延、能耗、租赁成本）
5. 训练 A3C 智能体实现最优卸载策略

(四) 仿真实验与性能评估

1. 搭建 Python 仿真平台
2. 对比 Local、MEC-only、DQN 等基准算法
3. 分析不同任务负载、不同 MEC 资源条件下的性能
4. 验证算法在收敛速度、系统成本、时延方面的优势

四、研究方法

(一) 文献综述法

系统调研 IoV、MEC、预测辅助、深度强化学习等领域的国内外文献，重点分析智能决策驱动卸载框架与 A3C 算法的研究进展。

(二) 数学建模法

构建通信模型、计算模型、能耗模型与 MDP 决策模型，为算法设计提供理论基础。

(三) 仿真实验法

基于 Python + PyTorch 搭建仿真环境，复现论文模型并进行对比实验，验证算法有效性。

五、研究手段

(一) 开发环境与工具

1. 开发环境、编程语言与框架：PyCharm 2022.3、Python（Conda 环境）、PyTorch（用于强化学习模型的训练与部署）；
2. 工具库：NumPy（数值计算）、Matplotlib（实验数据可视化）等。

(二) 数据支撑与实验平台

仿真训练平台包含信道增益、信道吞吐量、任务到达率、状态-策略-行动奖励值等。自建 IoV 仿真环境，支持 DT 状态同步与 DRL 训练。

六、预期成果

毕业设计报告 1 份，内容包括：

- | | |
|---------------|--------------|
| (1) 封面； | (2) 毕业设计任务书； |
| (3) 毕业设计开题报告； | (4) 中文摘要； |
| (5) 英文摘要； | (6) 目录； |
| (7) 论文正文； | (8) 参考文献； |
| (9) 附件 | |

七、任务安排

序号	设计（论文）各阶段名称	日期（教学周）
1	完成文献调研，重点研读预测辅助与 A3C 算法相关文献	2026.01.05~2026.01.11 (第 1 周)
2	配置 Python 仿真开发环境，确定研究的技术路线	2026.01.12~2026.01.25 (第 2 周-第 3 周)
3	完成外文翻译，撰写任务书和开题报告	2026.03.02~2026.03.22 (第 4 周-第 6 周)
4	实现车辆移动模型、任务生成模型、信道模型与计算模型，复现基准算法	2026.03.23~2026.04.05 (第 7 周-第 8 周)
5	构建 A3C 深度强化学习模型，结合预测辅助状态输入，进行模型训练与调试	2026.04.06~2026.04.19 (第 9 周-第 10 周)
6	设计并实现 LSTM/RNN 预测模块，完成吞吐量与任务到达率的预测功能	2026.04.20~2026.05.03 (第 11 周-第 12 周)
7	开展对比实验，调整权重参数，采集不同场景下的时延与能耗数据，分析算法性能	2026.05.04~2026.05.22 (第 13 周-第 15 周)
8	撰写毕业设计说明书，整理源代码与实验图表，毕业设计评审与答辩	2026.05.23~2026.05.31 (第 16 周)

八、完成任务所具备的条件因素

1. 理论基础：已掌握 Python 编程、机器学习等核心知识，熟悉强化学习的基本原理，具备数学建模与系统设计能力；
2. 开发环境：已配置 PyCharm、PyTorch 等开发工具与框架，具备搭建仿真平台的硬件与软件条件；
3. 文献资源：可通过学校图书馆获取 IEEE Xplore、CNKI 等数据库的相关文献，为研究提供充足的理论支撑；
4. 指导支持：指导教师长期从事车联网、边缘计算卸载研究，具备丰富的项目经验，能够为课题的技术路线设计、算法优化提供专业指导；

九、参考文献


- [1] D. Chen, Y.-C. Liu, B. Kim, J. Xie, C. S. Hong, and Z. Han, "Edge computing resources reservation in vehicular networks: A meta-learning approach," IEEE Trans. Veh. Technol., vol. 69, no. 5, pp. 5634–5646, May 2020.
- [2] A. A. Alahmadi, T. E. H. El-Gorashi, and J. M. H. Elmirghani, "Energy efficient and delay aware vehicular edge cloud," in Proc. IEEE Int. Conf. Transparent Opt. Netw., 2020, pp. 1–4.
- [3] J. Zhang, H. Guo, J. Liu, and Y. Zhang, "Task offloading in vehicular edge computing networks: A load-balancing solution," IEEE Trans. Veh. Technol., vol. 69, no. 2, pp. 2092–2104, Feb. 2020.
- [4] S.-S. Lee and S. Lee, "Resource allocation for vehicular fog computing using reinforcement learning combined with heuristic information," IEEE Internet Things J., vol. 7, no. 10, pp. 10450–10464, Oct. 2020.
- [5] P. Dai, K. Hu, X. Wu, H. Xing, and Z. Yu, "Asynchronous deep reinforcement learning for

- [6] data-driven task offloading in MEC-Empowered vehicular networks,” in Proc. IEEE Conf. Comput. Commun., 2021, pp. 1–10.
- [7] J. Du, F. R. Yu, X. Chu, J. Feng, and G. Lu, “Computation offloading and resource allocation in vehicular networks based on dual-side cost minimization,” IEEE Trans. Veh. Technol., vol. 68, no. 2, pp. 1079–1092, Feb. 2019.
- [8] W. Zhan et al., “Deep-reinforcement-Learning-Based offloading scheduling for vehicular edge computing,” IEEE Internet Things J., vol. 7, no. 6, pp. 5449–5465, Jun. 2020.
- [9] X. Zhu, Y. Luo, A. Liu, N. N. Xiong, M. Dong, and S. Zhang, “A deep reinforcement learning-based resource management game in vehicular edge computing,” IEEE Trans. Intell. Transp. Syst., vol. 23, no. 3, pp. 2422–2433, Mar. 2022.
- [10] Y. Mao, C. You, J. Zhang, K. Huang, and K. B. Letaief, “A survey on mobile edge computing: The communication perspective,” IEEE Commun. Surveys Tuts., vol. 19, no. 4, pp. 2322–2358, 4th Quart. 2017.
- [11] W. Almuseelem, “Deep reinforcement learning-enabled computation offloading: A framework for energy optimization and security-aware vehicular edge-cloud computing networks,” Sensors, vol. 25, no. 7, pp. 1–20, Mar. 2025.
- [12] A. Uddin, N. Zhang, and A. H. Sakr, “Task offloading in vehicular edge computing using deep reinforcement learning: A survey,” arXiv:2502.06963, 2025.
- [13] Y. Lu, X. Xu, and W. Wang, “Digital twin-driven smart manufacturing: Connotation, reference model, applications and research issues,” Robot. Comput.-Integr. Manuf., vol. 61, pp. 101–108, Feb. 2020.
- [14] H. Zhou, X. Li, Y. Zhang, and S. Mumtaz, “Digital-twin-enabled vehicular edge computing: Architecture, challenges, and solutions,” IEEE Netw., vol. 36, no. 5, pp. 123–129, Sep.–Oct. 2022.

指导教师意见及建议：

按照任务书要求顺利开展研究，同意开题。

指导教师签名：



2026 年 03 月 09 日