



长安大学

本科毕业设计

基于深度强化学习的车联网计算卸载研究

王钰博

学 院： 信息工程学院

专 业： 计算机科学与技术（卓越工程师）

学 号： 2022901300

指导教师： 刘树美

完成时间： 2026 年 05 月 25 日

二〇二六年六月

摘要

在车联网 (Internet of Vehicles, IoV) 中, 将计算密集型任务卸载至移动边缘计算 (Mobile Edge Computing, MEC) 服务器是满足低时延应用需求的关键技术。然而, 传统的任务卸载策略面临两方面核心挑战: 首先, 车辆的高速移动会导致频繁的越区切换与通信信道剧烈波动; 其次, 在任务到达的连续随机性与 MEC 计算资源的动态共享的背景下, 传统深度强化学习 (Deep Reinforcement Learning, DRL) 算法在进行决策时通常依赖当前时刻的环境状态快照, 这种“短视”决策在面临高动态的网络资源变化时, 极易导致卸载失败或陷入次优解。

为了应对上述挑战, 本文提出了一种基于 DRL 与预测辅助相结合的车联网任务卸载方法。首先, 构建了基于长短期记忆网络 (Long Short-Term Memory Network, LSTM) 的环境状态前瞻模块, 利用车辆的历史时序数据提取网络资源波动的时空特征, 并对未来的 MEC 吞吐量、云端吞吐量及任务到达率进行前瞻性的精准预测。其次, 将任务卸载过程建模为马尔可夫决策过程 (Markov Decision Process, MDP), 旨在最小化由任务时延、系统能耗及云端租赁成本构成的长期系统总开销。在此架构下, 本文设计了预测增强型的异步优势演员-评论家 (Prediction-Assisted Asynchronous Advantage Actor-Critic, PA-A3C) 算法, 将 LSTM 预测模块对未来的预判能力无缝融入深度强化学习智能体的高维状态空间中, 使系统能够主动感知越区风险, 并智能统筹本地、MEC 与云端的协同卸载。大量实验表明, 与其他方法相比, 本文提出的方法在快速收敛和降低系统成本方面表现出色。

关键词: 车联网, 任务卸载, 深度强化学习, 边缘计算, 长短期记忆网络 (LSTM)

ABSTRACT

In the Internet of Vehicles (IoV), offloading computation-intensive tasks to Mobile Edge Computing (MEC) servers is a key technology to satisfy the requirements of low-latency applications. However, traditional task offloading strategies face two core challenges. First, the high-speed mobility of vehicles leads to frequent handovers and severe fluctuations in communication channels. Second, under the background of the stochastic nature of task arrivals and the dynamic sharing of MEC computing resources, traditional Deep Reinforcement Learning (DRL) algorithms typically rely on the current environmental state snapshots when making decisions. Such "myopic" decision-making is highly prone to resulting in offloading failures or falling into sub-optimal solutions when confronting highly dynamic network resource changes.

To address the aforementioned challenges, this thesis proposes a vehicular task offloading method combining DRL and prediction assistance. First, an environmental state forecasting module based on the Long Short-Term Memory (LSTM) network is constructed. It utilizes the historical time-series data of vehicles to extract the spatio-temporal features of network resource fluctuations, thereby making proactive and accurate predictions on future MEC throughput, cloud throughput, and task arrival rates. Second, the task offloading process is modeled as a Markov Decision Process (MDP), aiming to minimize the long-term total system overhead composed of task delay, system energy consumption, and cloud leasing costs. Under this architecture, this thesis designs a Prediction-Assisted Asynchronous Advantage Actor-Critic (PA-A3C) algorithm. By seamlessly integrating the futuristic prediction capability of the LSTM module into the high-dimensional state space of the reinforcement learning agent, the system is enabled to proactively perceive handover risks and intelligently orchestrate collaborative offloading among the local device, MEC, and the cloud.

KEYWORDS: Internet of Vehicles, Task Offloading, Deep Reinforcement Learning, Edge Computing, Long Short-Term Memory (LSTM)

目 录

第一章 绪论	1
1.1 研究背景与动机	1
1.2 相关工作	3
1.2.1 基于传统优化和启发式的卸载算法	3
1.2.2 基于 DRL 的动态卸载策略	3
1.2.3 基于环境预测辅助的智能卸载策略	4
1.2.4 国内相关研究与综述	5
1.2.5 现有研究的局限性与本文研究动机	5
1.3 研究内容与本文贡献	6
第二章 系统模型	9
2.1 系统描述	9
2.2 信道模型	10
2.3 本地计算模型	12
2.4 MEC 计算模型	12
2.5 云计算模型	13
2.6 优化目标与问题建模	14
2.7 本章小结	15
第三章 基于 LSTM 与 A3C 的任务卸载算法设计	17
3.1 DRL 背景	17
3.2 任务卸载的 MDP 建模与状态空间设计	18
3.2.1 动作空间 ($\mathcal{A}$)	18
3.2.2 状态空间 ($\mathcal{S}$)	19
3.2.3 综合奖励函数 ($\mathcal{R}$)	19
3.3 LSTM 网络结构设计	20
3.4 深度网络架构与 A3C 训练机制	21
3.4.1 Actor-Critic 双网络结构	21
3.4.2 异步梯度更新机制	21

3.5 本章小结	22
第四章 预测辅助仿真系统设计与实现	25
4.1 仿真平台总体架构与运行机制	25
4.2 物理层底座的面向对象建模与实现	26
4.2.1 车辆实体与动态任务生成引擎	26
4.2.2 Jakes 多普勒信道演进模块	26
4.3 系统仿真环境的核心调度逻辑	27
4.3.1 高维状态的拼接与张量化	27
4.3.2 越区中断与物理开销的代码级结算	27
4.4 A3C 并行训练引擎的底层实现	28
4.4.1 共享内存优化器与并发拓扑	28
4.4.2 梯度异步回传与网络同步	28
4.5 本章小结	29
第五章 仿真实验与结果分析	31
5.1 仿真环境与参数设置	31
5.2 基准方法	32
5.3 LSTM 预测评估	32
5.3.1 LSTM 真实值与预测值的比对机制	32
5.3.2 预测性能分析	33
5.4 强化学习算法的训练与收敛性分析	36
5.4.1 奖励设计与动作生态位博弈分析	36
5.4.2 策略探索与综合奖励收敛评估	36
5.4.3 任务时延优化的分析	37
5.4.4 通信系统能耗的隐性降低	38
5.5 多场景综合评估	39
5.5.1 场景 A：马尔可夫动态负载标准测试	39
5.5.2 场景 B：静态队列扫描（压力测试）	40
5.5.3 场景 C：恒定负载下的动态时序追踪	41

5.6 本章小结	42
结论与展望	43
致 谢	47
参考文献	49

第一章 绪论

1.1 研究背景与动机

随着第五代（Fifth Generation, 5G）移动通信技术与物联网的深度融合，车联网（Internet of Vehicles, IoV）迎来了蓬勃发展。现代智能网联汽车搭载了海量的新型车载应用，如自动驾驶、增强现实（Augmented Reality, AR）导航以及实时路况视频分析等。这些应用具有典型的计算密集型与时延敏感型特征。然而，受限于车辆本地有限的电池容量与计算资源等物理瓶颈，仅依靠本地处理难以满足业务的严苛时延要求。在此背景下，移动边缘计算（Mobile Edge Computing, MEC）应运而生，通过在靠近车辆的路侧单元（Roadside Unit, RSU）上部署边缘服务器，车辆可以将复杂的计算任务卸载至边缘侧或云端处理，从而有效缓解本地资源瓶颈。

然而，在真实的车联网环境中，实现高效的计算卸载面临着极大的动态性挑战。首先，车辆的高速移动特性导致网络拓扑频繁变化。无线通信信道不仅受大尺度路径损耗影响，更时刻经历着复杂的多普勒小尺度衰落（如 Jakes 衰落），这使得车辆与 RSU 之间的上行及下行传输速率呈现出剧烈的非线性波动。此外，当车辆驶出当前 RSU 的覆盖范围时，还会引发不可避免的越区切换甚至通信中断。其次，车载任务的生成往往具有突发性与连续随机性，叠加多用户对有限 MEC 算力的竞争共享，使得边缘网络的可用资源状态时刻处于高度的不确定性之中。车辆如果仅凭借本地局部信息做出“短视”的调度决策，极易陷入次优解。上述挑战促使本文关注一个基础性的研究问题：如何通过将未来任务的到达纳入考量，来设计一种高效、可靠的卸载策略，从而实现平滑的任务计算。

如图 1-1、图 1-2 分别展示了传统车联网与预测辅助赋能的车联网之间的区别。在图 1-1 所示的传统车联网中，从邻居节点收集驾驶环境相关信息需要多跳无线车际通信，这可能是昂贵且不可靠的，结果导致其他 MEC 服务器的信息通常不可用。在图 1-2 所示的预测辅助赋能的车联网中，云端可以获取全局环境网络和车辆的历史运行信息，借助车辆和道路的全局信息来规划车辆在整个行程中的卸载策略。本文旨在基于深度强化学习与长短期记忆（Long Short-Term Memory Network, LSTM）预测辅助，开发出兼顾动态网络状态和任务需求的最优卸载策略。




图 1-1 传统车联网




图 1-2 预测辅助赋能的车联网

因此，探索如何打破传统强化学习的短视局限，赋予决策智能体“预知未来”的能力，实现从“被动响应”到“主动避险”的范式转变，具有重要的学术价值与工程意义。本课题正是在此背景下，致力于研究基于预测辅助的深度强化学习计算卸载策略。通过引入深度时序神经网络（如 LSTM）精准提取车辆轨迹与信道波动的时空特征，为强化学习提供具有前瞻性的高维状态视野。这不仅具有打破传统深度强化学习（Deep Reinforcement Learning, DRL）感知瓶颈的深远学术价值，更为实现高可靠、低时延的

车联网“云-边-端”协同计算提供了极具现实意义的工程解决方案。

1.2 相关工作

随着智能网联汽车与第五代移动通信技术深度融合，IoV 已成为支撑自动驾驶、AR 导航等时延敏感型应用的关键基础设施，而将计算密集型任务卸载至 MEC 服务器成为了突破车载硬件瓶颈的主流技术路径^{[1][2]}。纵观该领域的发展轨迹，计算卸载策略经历了从传统数学优化与启发式算法，到基于深度强化学习的动态卸载策略，再到如今基于环境预测机制辅助的智能卸载策略的演进历程。

1.2.1 基于传统优化和启发式的卸载算法

早期计算卸载研究多建立在精确数学建模与凸优化理论之上，将任务卸载决策、带宽分配、算力调度联合建模为混合整数非线性规划（Mixed-Integer Non-Linear Programming, MINLP）问题。Du 等人^[3]从车辆与 MEC 服务器双边成本最小化出发，采用拉格朗日对偶分解与启发式算法求解帕累托最优资源分配方案，同时兼顾时延、能耗与服务提供商成本。Guo 等人^[4]研究了光纤无线网络下协作计算卸载的联合优化。为了应对动态到达引发的延迟问题，Jiang 等人^[5]提出了面向截止时间约束的车联网任务复制策略，而 Zhao 等人^[6]则探索了部分卸载的优化方法。

在面临环境动态性时，传统方法也展现出了一定的适应性扩展。针对无人机（Unmanned Aerial Vehicle, UAV）辅助的 MEC 场景，Zeng 与 Tang^[7]研究了通用任务下 UAV 的实时数据采集与处理；Shah 等人^[8]则重点优化了灾害场景下的 UAV 部署与计算效率。此外，Chen 等人^[9]利用元学习方法实现了边缘计算资源的提前预留。

尽管传统优化方法理论完备，但在高动态车联网场景中存在明显缺陷：一方面，MINLP 问题属于 NP-hard 问题，随网络规模扩大复杂度呈指数爆炸，难以满足毫秒级实时决策；另一方面，模型高度依赖瑞利衰落、准静态信道等先验假设，一旦车辆高速移动引发多普勒频移与频繁越区切换，基于静态假设的解将迅速失效。

1.2.2 基于 DRL 的动态卸载策略

为摆脱对环境先验模型的依赖，DRL 成为应对高动态车联网资源分配的主流方案。

DRL 通过智能体与环境试错交互,在马尔可夫决策过程中直接学习最优调度策略。Mnih 等人^[10]提出的深度 Q 网络(Deep Q-Network, DQN)为高维状态空间的处理奠定了基础。随后,Zhan 等人^[11]将 DRL 广泛应用于车联网边缘计算卸载调度中,以权衡时延与能耗。针对离散与连续动作并存的复杂分配问题,Liu 与 Liao^[12]提出了 Actor-Critic 模型联合处理无线与计算资源的分配。

为了进一步挖掘通信与缓存的协同潜力,He 等人^[13]提出了基于 DRL 的联合网络、缓存与计算的优化方案,Zhou 等人^[14]则引入了激励驱动的 D2D 卸载策略。在无线携能及博弈场景中,Huang 等人^[15]优化了无线供电 MEC 的在线卸载,Zhu 等人^[16]在车联网中构建了基于 DRL 的资源管理博弈模型。针对空地协同网络,Cheng 等人^[17]探索了空天辅助的物联网任务卸载,Zhao 等人^[18]则提出了适用于 UAV 辅助 MEC 的多智能体 DRL (Multi-agent Deep Reinforcement Learning, MADRL) 算法。此外,为解决集中式训练的扩展性瓶颈,Yang 等人^[19]提出了联邦机器学习架构。Dai 等人^{[20][21]}将异步深度强化学习与联邦机制引入数据驱动的卸载架构中,以多线程并行打破数据强相关性。

尽管 DRL 方法突破了传统优化的实时性瓶颈,但现有方案普遍存在短视性缺陷:智能体仅依赖当前时刻环境快照决策,无法预判未来信道波动与越区风险,在跨越 RSU 覆盖边界时易因断连引发任务失败,导致策略保守退化。

1.2.3 基于环境预测辅助的智能卸载策略

为解决 DRL 的短视决策问题,学术界开始引入时序预测、数字孪生(Digital Twin, DT)等技术构建物理实体的虚拟映射与演进预测^{[1][22]}。Zheng 等人^[23]首次将物理镜像与异步优势演员-评论家(Asynchronous Advantage Actor-Critic, A3C)算法结合,通过提取历史时序数据预测未来吞吐量,将预测值融入状态空间实现主动避险。Zhang 等人^[24]提出了虚拟推演辅助的计算卸载与服务缓存联合优化框架,将卸载、服务缓存、资源分配联合建模,利用深度确定性策略梯度(Deep Deterministic Policy Gradient, DDPG)算法最小化系统长期能耗。Sun 等人^[25]着眼于 6G 网络,探讨了边缘网络中降低卸载延迟的方法。

在无人机与自动驾驶飞行器系统中,预测与镜像推演的潜力被进一步激发。Liang 等人^[26]将预测映射与 DRL 结合,并利用变分自编码器^[27]生成模拟数据以提升训练效率。

Hu 等人^[28]和 Li 等人^[29]深入研究了辅助轨迹设计与预测性任务卸载。为了优化物理层传输环境, Yuan 等人^[30]结合智能反射面^[31]提出了数据驱动的卸载与 IRS 配置框架。此外, 前瞻性辅助推演技术在社交感知内容缓存^[32]、车辆协同匝道汇入^[33]、交通基础设施能效评估^[34]以及工业物联网空地协同^{[35][36]}等复杂车联网场景下均展现出了极其卓越的网络编排与前瞻预测能力。

1.2.4 国内相关研究与综述

除了上述前沿的具体算法研究, 国内学者在车联网边缘计算与智能卸载领域也进行了大量系统性的综述与展望, 为本课题的发展脉络提供了重要参考。谢人超等人^[37]详细梳理了移动边缘计算的任务卸载技术, 从时延优化和能耗最小化等维度为边缘协同计算模型奠定了理论框架。随着人工智能的深度融合, 康宇等人^[38]全面调研了 AI 算法在车联网通信与计算中的应用, 着重指出了深度强化学习在处理高动态算力分配与多维状态空间建模中的绝对优势与通算融合的趋势。此外, 在应对复杂环境感知与预判方面, 孙滔等人^[39]系统地论述了数字孪生网络的概念、架构及关键技术, 为车联网通过物理镜像提取时序特征以辅助前瞻性决策提供了宏观的架构指导。这些系统性的综述研究共同指明: 在高度动态的车联网场景中, 打破单一瞬时状态的局限, 引入历史特征与前瞻性预测来辅助强化学习智能体, 已成为突破现有性能瓶颈的必然趋势。

1.2.5 现有研究的局限性与本文研究动机

综合梳理上述, 针对“传统数学优化→深度强化学习→环境预测机制辅助”的技术演进路线可以发现, 尽管学术界已经在大规模资源分配与动态自适应方面构建了丰富的理论大厦, 但在面向强动态、高惩罚的极速车联网场景时, 现有研究仍存在亟待突破的局限性:

第一, 历史信息与强化学习高维状态空间的割裂: 目前大部分应用 DRL 的卸载研究(包括诸多采用 DQN 或 DDPG 的方案)依然将状态空间局限于低维的瞬时观测值。即使部分方案采用了时序预测工具, 也往往只是将其作为前置的数据平滑手段, 未能将深度的历史时序特征与未来多步预测值“无缝且显式”地映射进强化学习(Reinforcement Learning, RL)智能体的策略网络中, 导致智能体无法理解时间维度上的演进逻辑。

第二,越区中断风险的被动妥协与刻板调度:在车辆高速跨越 RSU 的物理边界时,传统算法往往因为无法感知物理距离的拉近,做出将庞大计算任务卸载至即将断连的 MEC 的错误决策。现有的惩罚机制使得智能体在试错后变得极端保守,往往退化为不顾网络状态全部推向云端的次优策略,缺乏在 MEC 安全区与云端避险区之间游刃有余的主动切换机制。

第三,复杂高维连续空间下的采样效率低下:在集成系统环境的历史与预测数据后,强化学习面临的维度灾难成倍增加。传统的单线程 RL 算法在庞大状态空间下的经验回放池极易产生数据同质化,导致神经网络陷入严重的局部极小值收敛,难以在短时间内锁定最优协同解。

基于上述深刻的理论痛点,本文在深度借鉴 Actor-Critic 架构处理异构资源空间的优势以及异步多线程机制应对高动态拓扑的先进思想的基础上,以预测辅助赋能的智能车联网架构为核心底座,展开针对性研究。本文旨在通过构建多维度高保真的 LSTM 预测引擎,并辅以预测增强型的异步优势演员-评论家(Prediction-Assisted Asynchronous Advantage Actor-Critic, PA-A3C)算法,赋予系统“感知历史、预判未来、主动避险”的核心能力,以期在规避越区灾难性中断的前提下,实现车联网边缘计算在时延、能耗与租赁经济成本上的严格帕累托最优平衡。

1.3 研究内容与本文贡献

针对现有调度机制中,在应对动态越区风险和任务连续性突发时的迟钝性,本文在 LSTM 预测赋能的仿真架构下,提出了一种兼具历史记忆与未来视野的深度强化学习任务卸载方法。主要研究工作与贡献如下:

(1) 引入了 LSTM 预测机制。该机制剥离了传统强化学习仅依赖瞬时状态进行试错的局限,构建了基于长短期记忆网络的预测辅助核心。利用系统环境中车辆轨迹与信道网络历史数据,提取信道衰落与车辆移动的隐藏周期性规律,精准输出未来的 MEC/云端吞吐量及任务到达率。

(2) 构建了多维成本最小化的马尔可夫决策过程(Markov Decision Process, MDP)模型。将复杂的卸载决策映射为 MDP 模型,严谨量化了不同卸载路径下的执行时延、通信计算能耗以及云端租赁成本,并将其加权作为系统长期优化的基准反馈,为算法收

敛提供了清晰的导向。

(3) 设计了预测增强型的 PA-A3C 算法。面对庞大连续状态空间下深度强化学习采样效率低的痼疾，本文采用多线程并行的 A3C 架构。通过将 LSTM 预测的高维特征输入策略网络，智能体不仅能感知当下的算力瓶颈，更具备了提前切换传输链路以规避越区中断的“主动避险”能力，彻底改变了面对惩罚时只能被动退避的传统调度逻辑。

第二章 系统模型

本章将基于 LSTM 预测辅助的车联网任务卸载服务的仿真架构，针对车联网高动态、强时变的网络特征，从物理实体的建模视角出发，严谨推导了包含通信信道、本地计算、边缘计算（MEC）以及云计算在内的多种数学模型，并最终将复杂的调度寻优问题严谨地抽象为马尔可夫决策过程下的成本最小化的数学规划问题。

2.1 系统描述

在 LSTM 预测辅助的车联网场景中，车辆连接到配备了 MEC 服务器的 RSU 以获取边缘计算服务。通过蜂窝基站链路，车辆可以与云服务器中维护的系统环境进行交互。通过聚合全局信息，然后将这些信息用于卸载决策模块以优化卸载决策。

具体来说，对于某个特定任务，Agent 通过观察当前状态做出卸载决策，并将决策发送给本地车辆执行。当前状态包括无线状态、任务信息和资源状态。无线状态包括信道增益和预测吞吐量，而任务状态包括任务信息（即数据大小和任务所需的计算资源）以及预测的任务到达状态。对于资源状态，它包括 MEC 服务器的资源可用性和车辆的能量信息。一旦当前任务完成，Agent 就会根据当前状态为下一个任务做出卸载决策，并与车辆实时更新参数。为了提高发生切换时的信道利用率，本工作假设不允许在两个 RSU 之间传输任务数据（执行结果除外）。

在的车联网场景中，高速行驶的车辆节点集合由 $\mathcal{V} = \{v_1, v_2, \dots, v_N\}$ 表示，沿道路均匀部署的 RSU 及附属 MEC 服务器集合由 $\mathcal{M} = \{m_1, m_2, \dots, m_K\}$ 表示。令 $||Q||$ 表示任务队列长度， $q(t)$ 是时间槽 t 时任务队列的积压量。相邻 RSU 之间的平均距离假定为 L 米，车辆以 $v = 10$ m/s 的恒定速度行驶，随着物理位置的推移，车辆将不断穿越不同 RSU 的无线覆盖范围，这种高频的空间位置变化将会直接引发通信链路的剧烈波动，甚至越区中断。

为了突破物理层的感知局限，车辆通过独立的蜂窝基站链路与云端服务器保持连接。云端维护着一个包含所有车辆、RSU/MEC 及通信资源的高保真仿真环境。本文假设在系统环境中，使用一个五元组来表征时间槽 t 物理世界中的车辆 v ，可以表示为 $DT_v(t) = \{Q_v(t), f_v^l, loc_v^l(t), \Gamma(t), \Phi_v(t)\}$ ，其中 $Q_v(t)$ 是队列状态， f_v^l 表示本地车辆的

计算资源。 $loc_v^l(t)$ 是 v 的当前位置， $\Gamma(t)$ 是时间 t 的任务参数（例如，任务队列中任务的数据大小和所需的计算资源）。 $\Phi_v(t)$ 表示与车辆相关的其他参数。

任务队列中的任务 i 可以表示为 $\{d_i, cr_i, T_i^{max}\}$ 。这里， d_i 表示该任务的输入数据大小。 cr_i （以 CPU 周期为单位）表示完成任务 i 所需的计算资源数量。 T_i^{max} 是任务的最大延迟容忍度。本文假设系统采用先到先服务（First-Come First-Served, FCFS）的调度方法。在每次调度开始时，每个 Agent 根据当前状态信息，综合全局的预测信息，从动作空间 $\mathcal{A} = \{0,1,2\}$ 中为任务 i 做出决策，其中 $\{0\}$ 到 $\{2\}$ 分别代表本地执行（Local）、边缘执行（MEC）和云端执行（Cloud）。

车辆在行驶过程中，各类车载应用（如环境感知、AR 导航）会持续生成计算密集型任务，其中，任务到达通常被建模为服从泊松分布的随机过程。考虑到真实城市路况的复杂性，本文在系统仿真中引入了马尔可夫链驱动的动态负载模型。本文假设任务到达服从速率为 λ 的泊松过程，并且马尔可夫链中的任务到达率每 20 个时隙变化一次。在现实场景中，复杂的道路环境（如高密度的车辆和建筑物）或驾驶员频繁的驾驶指令切换（如刹车、转向和变道），都可能会导致短时间内任务数量激增，从而导致更高的 λ 值。与此同时，在不同时间段，任务的到达率也可能不同。在具体实现中，任务的到达率 λ 服从状态空间为 $\{0.1, 0.3, 0.5, 0.7, 0.9\}$ 的马尔可夫链模型，以模拟车辆在真实路况下任务负载的动态骤变。

2.2 信道模型

由于车辆的高速移动性，车联网的无线信道不仅受到自由空间路径损耗的影响，更面临由多普勒频移和多径效应引发的严重小尺度衰落。本文采用块衰落模型，假设信道增益在单一时隙内保持恒定，但在时隙间遵循严密的随机演进。在本节中，本文分别构建了 MEC 与车辆之间，以及车辆与云服务器之间的信道模型。当 Agent 做出卸载决策时，会考虑动态的信道环境和过去的信道增益。

本文考虑一个持续时间为 T 的完全同步的时间槽系统，并假设每辆车具有单根天线，同时参考使用块衰落模型来表示信道增益，并假设信道增益在同一持续时间内保持不变。因此，本方案中可以表示时间槽 t 时车辆 v_n 和 MEC 服务器 m_k 之间的信道增益，即：

$$g_{n \rightarrow k}^t = |h_{n \rightarrow k}^t|^2 \vartheta_{n \rightarrow k}^t, t = 1, 2, \dots \quad (2-1)$$

其中 $h_{n \rightarrow k}^t$ 表示小尺度衰落, $\vartheta_{n \rightarrow k}^t$ 是大尺度路径损耗和阴影。本文采用块衰落信道模型（即 Jakes 模型），并使用一阶 Gauss-Markov 过程来描述小尺度衰落分量。 $h_{n \rightarrow k}^t$ 的更新给出为：

$$h_{n \rightarrow k}^t = \kappa h_{n \rightarrow k}^{t-1} + l_{n \rightarrow k}^t \quad (2-2)$$

其中 $h_{n \rightarrow k}^0 \sim \mathcal{CN}(0,1)$ 是具有单位方差的圆对称复高斯分布，而 $l_{n \rightarrow k}^1, l_{n \rightarrow k}^2, \dots$ 表示分布为 $\mathcal{CN}(0, 1 - \kappa^2)$ 的信道更新过程。根据 Jakes 模型，相关性可定义为：

$$\kappa = J_0(2\pi f_D \hat{T}) \quad (2-3)$$

其中 $J_0(\cdot)$ 是零阶贝塞尔函数。最大多普勒频率定义为 $f_D = v f_c / c$ ，其中 v 是车辆的速度， f_c 是载波频率， $c = 3 \times 10^8$ m/s 是电磁波在空气中的传输速率， $\hat{T}$ 表示 CSI 反馈间隔。在本文既定的物理设定下，信道呈现出极强的马尔可夫时序特征，为后续使用 LSTM 网络进行特征提取提供了坚实的数学基础。

对于大尺度衰落，本文采用 $distance^\alpha$ 模型进行仿真，根据自由空间传播理论，本文采用距离的指数衰减模型，随着车辆驶离当前 RSU（MEC）中心向边缘移动， $distance(t)$ 会逐渐增大，接收信号强度将呈现几何级数级的锐减。

$$v_{n \rightarrow k}^t = distance_t^\alpha \quad (2-4)$$

综上所述，基于香农定理，数据传输率可以表示为：

$$C_{n,k}^t = B_{n,k} \log_2 \left(1 + \frac{g_{n \rightarrow k}^t p_n^{tx}}{\sigma^2} \right) \quad (2-5)$$

这里 σ^2 是加性高斯白噪声功率谱密度， $B_{n,k}$ 表示 m_k 分配给 v_n 的可用带宽。 p_n^{tx} 是车辆的传输功率。

类似地，本文将车辆 n 与云端之间的可达传输率表示为：

$$C_{n,c}^t = B_{n,c} \log_2 \left(1 + \frac{g_{n \rightarrow c}^t p_n^{tx}}{\sigma^2} \right) \quad (2-6)$$

其中 $g_{n \rightarrow c}^t$ 表示车辆 n 与云服务器之间的信道增益， $B_{n,c}$ 是云分配给车辆的带宽。

2.3 本地计算模型

在本地计算模型中，如果 Agent 发送给车辆的卸载决策为 $a_i = 0$ ，则任务 i 在本地车辆上执行。在这种情况下，处理任务的本地成本包括执行时间和能量消耗。执行时间由可用的计算能力和任务对资源的要求共同决定，无需通过无线网络传输数据，从而彻底规避了通信传输时延和越区中断风险。对于车辆 n ，任务 i 执行时间可以计算为：

$$T_l^{ex}(n, i) = \frac{cr_i}{f_n^l} \quad (2-7)$$

其中 cr_i 表示任务 i 所需的计算资源， f_n^l （即每个时间槽的 CPU 周期数）是车辆 n 的计算资源。在公式 (2-7) 中，根据 CMOS 集成电路的动态功耗原理， f_n^l 满足 $p_n = \zeta(f_n^l)^\tau$ ，其中 ζ 是取决于芯片架构的有效开关电容， τ 是一个常数。因此，给定每个时间槽的能耗，记为 p_n ，计算任务 i 的本地能耗给出如下：

$$E_l^{ex}(n, i) = p_n \cdot T_l^{ex}(n, i) \quad (2-8)$$

2.4 MEC 计算模型

当 Agent 做出的卸载决策为 $a_i = 1$ 时，触发 MEC 计算模型。与本地计算模型相比，此情况下的总成本由任务传输和任务计算决定。此外，该模型还考虑了无线通信的动态性以及 MEC 服务器计算资源的可用性。传输时间可以直观地表示为：

$$T_k^{tx}(n, i) = \frac{d_i}{C_{n,k}^t} \quad (2-9)$$

其中 d_i 是任务 i 的数据大小。需要注意的是，一个任务可能需要多个时间槽才能完成从车辆到 MEC 服务器的传输。如果在时间槽 t 内未完成传输，传输率可能会在时间槽 $t+1$ 发生变化。因此，任务 i 从车辆 n 到 MEC_k 的完整传输过程应满足 $\int_{t_{start}}^{t_{end}} C_{n,k}^t dt = d_i$ 。此时，传输时间可以通过 $t_{end} - t_{start}$ 获得。在本文的工作中，将会使用迭代方法来计算它。具体来说，本文假设车辆决定在时间槽 t_{start} 将任务 i 卸载到 MEC 服务器，并初始化指示器 $D_i^{t_{start}} = d_i$ 。相应地， D_i^t 的更新遵循：

$$D_i^t = \max\{D_i^{t-1} - T \cdot C_{n,k}^{t-1}, 0\} \quad (2-10)$$

其中 D_i^t 表示时间槽 t 时任务 i 剩余的传输数据大小， T 是两个相邻时间槽之间的时

间间隔。本文假设在时间槽 t_{end} 时, $D_i^{t_{end}} = 0(t_{end} > t_{start})$, 任务 i 的传输时间可以定义为:

$$T_k^{tx}(n, i) = t_{end} - t_{start} \quad (2-11)$$

在实践中, 车辆通常是受能量约束的设备, 能源效率是一个普遍的目标。因此, 考虑将任务 i 从车辆 n 传输到 MEC 服务器 k 的能耗非常重要。该能耗可以表示为:

$$E_k^{tx}(n, i) = p_n^{tx} \cdot T_k^{tx}(n, i) \quad (2-12)$$

其中 p_n^{tx} 是车辆 n 的传输功率。

任务传输到 MEC 服务器后, 任务将立即执行。值得注意的是, 通常部署在 RSU 上的 MEC 服务器同时为多辆车提供服务, 这会导致不同时间槽的计算资源可用性不断变化。为了捕捉这一特性, 本文将 MEC 计算资源的可用性建模为一个随机过程。与公式 (2-10) 类似, 有 $F_i^{t_{start}} = cr_i$, 并且 F_i^t 的更新遵循:

$$F_i^t = \max\{F_i^{t-1} - T \cdot f_k^{t-1}, 0\} \quad (2-13)$$

其中 F_i^t 和 f_k^t 分别表示时间槽 t 时完成任务 i 所需的剩余计算资源和 MEC 服务器 k 的可用计算资源。本文假设在 t_{end} 时, $F_i^{t_{end}} = 0$ ($t_{end} > t_{start}$), 并且在 MEC 服务器 k 上完成任务 i 的执行时间表示为:

$$T_k^{ex}(n, i) = t_{end} - t_{start} \quad (2-14)$$

与此同时, 在 MEC 计算模型中, 本文忽略了任务执行的能耗, 因为它对卸载决策没有影响。

2.5 云计算模型

云端卸载通过独立的蜂窝网络进行传输, 与局域的 MEC 链路不同, 宏基站蜂窝网络具有连续的全域覆盖特性, 云端卸载天然免疫越区切换失败的风险。在该模型中, 对于任务 i , Agent 向车辆发送卸载动作 $a_i = 2$, 车辆通过当前连接的蜂窝基站链路经由互联网将任务 i 传输到云服务器。借鉴 MEC 计算模型的思想, 本方案可以计算任务 i 从车辆 n 到云端的传输时间, 记为 $T_c^{tx}(n, i)$ 。因此, 任务传输的能耗表示如下:

$$E_c^{tx}(n, i) = p_n^{tx} \cdot T_c^{tx}(n, i) = p_n^{tx} \cdot \frac{d_i}{C_{n,c}^t} \quad (2-15)$$

此外, 云端卸载过程中使用互联网的成本不容忽视。本文假设通过互联网传输数据

的单位成本（即每 MB 数据的成本）为 ϖ_{tx} 。因此，将任务 i 从车辆 n 传输到云服务器的总成本可以表示为：

$$rc_c^{tx}(n, i) = \varpi_{tx} \cdot d_i \quad (2-16)$$

通常，云服务器由许多具有强大计算资源的服务器组成，因此，本文假设在任务执行期间云计算资源是恒定的（记为 f_c ）。在云服务器上完成任务 i 的计算时间给出为：

$$T_c^{ex}(n, i) = \frac{cr_i}{f_c} \quad (2-17)$$

此外，令 ϖ_{ex} 表示使用云的成本，这与任务所需的计算资源有关。任务 i 的计算成本可以表示为：

$$rc_c^{ex}(n, i) = \varpi_{ex} \cdot (cr_i)^\mu \quad (2-18)$$

其中 $\mu \geq 1$ 是与云服务提供商相关的价格因子。

2.6 优化目标与问题建模

车联网任务调度的核心目标是在极度动态的无线网络中，通过优化卸载决策序列 $\mathcal{A}$ ，最小化系统的长期综合开销。为了平衡时延敏感性、设备续航要求以及经济成本，本文采用标量化权重法将不同维度的开销融合，以构建统一的系统成本函数。

基于上述分析，任务的总成本包括执行时间、能量消耗和租赁成本（如果任务卸载到云端）。因此，本文将任务 i 的时间成本建模为：

$$\Psi(n, i) = \begin{cases} T_l^{ex}(n, i), & \text{if } a_i = 0. \\ T_k^{tx}(n, i) + T_k^{ex}(n, i), & \text{if } a_i = 1. \\ T_c^{tr}(n, i) + T_c^{ex}(n, i), & \text{if } a_i = 2. \end{cases} \quad (2-19)$$

其中 n 和 k 分别是目标车辆和 MEC 服务器。任务的能耗成本可以表示为：

$$\Omega(n, i) = \begin{cases} E_l^{ex}(n, i), & \text{if } a_i = 0. \\ E_k^{tr}(n, i), & \text{if } a_i = 1. \\ E_c^{tr}(n, i), & \text{if } a_i = 2. \end{cases} \quad (2-20)$$

类似地，任务的租赁成本定义为：

$$\Upsilon(n, i) = \begin{cases} 0, & \text{if } a_i = 0. \\ 0, & \text{if } a_i = 1. \\ rc_c^{tr}(n, i) + rc_c^{ex}(n, i), & \text{if } a_i = 2. \end{cases} \quad (2-21)$$

本文正式将总成本定义为执行时间、能耗和租赁成本的加权和，记为：

$$\Gamma(n, i) = \sum_{i=1}^{\omega} \{\xi_1 \Psi(n, i) + \xi_2 \Omega(n, i) + \xi_3 \Upsilon(n, i)\} \quad (2-22)$$

其中 ξ_1 、 ξ_2 和 ξ_3 是权重因子，分别代表各项成本对任务总成本的重要性。

本文的目标是最小化车辆中任务的长期成本。目标函数可以表示为：

$$\min_A \lim_{W \rightarrow \infty} \frac{1}{W} \sum_{i=1}^W \Gamma(n, i) \quad (2-23a)$$

$$s.t. \sum_{j=1}^3 \xi_j = 1, \quad (2-23b)$$

$$a_i \in \{0,1,2\}, \forall i \in Z^+, \quad (2-23c)$$

$$t_i \leq T_i^{max}, \forall i \in Z^+, \quad (2-23d)$$

$$0 \leq f_k^t \leq f_k^{max}, \forall k \in M, t = 1, 2, \dots, \quad (2-23e)$$

$$0 \leq f_c \leq f_c^{max}, \quad (2-23f)$$

$$0 \leq p_n^{tx} \leq p_n^{tx, max}, \quad (2-23g)$$

$$q(t) \leq ||Q||, t = 1, 2, \dots, \quad (2-23h)$$

$$rp(t) > 0, t = 1, 2, \dots, \quad (2-23i)$$

其中 $\mathcal{A} = \{0,1,2\}$ 是卸载决策的集合。约束 (2-23b) 表明权重系数之和为 1。(2-23c) 表明动作只能从本地车辆、MEC 服务器和云端中选择。(2-23d) 确保每个任务的执行时间不能大于系统所能容忍的时间。(2-23e) 和 (2-23f) 分别是 MEC 服务器和云允许分配给车辆的最大计算资源约束。(2-23g) 表示车辆最大传输功率的约束。(2-23h) 显示在时间槽 t ，车辆中任务的数据大小不能超过队列长度的上限。(2-23i) 表明在时间槽 t 剩余电量必须大于零。

2.7 本章小结

本章立足于预测辅助的车联网任务卸载场景，详细构建了涵盖“云-边-端”三层协同的物理与数学系统模型。首先，阐述了高动态车联网的总体系统架构，并引入了基于马尔可夫链驱动的动态任务到达模型，以高度还原真实路况下的突发计算负载。其次，针对车辆高速移动的物理特性，严谨构建了包含大尺度路径损耗与 Jakes 多普勒小尺度快衰落的无线通信信道模型。在此基础上，分别对本地终端计算、MEC 边缘计算以及云端计算三种卸载模式进行了深度的数学建模，精确量化了不同卸载路径下的任务执行时延、通信与计算能耗，以及云端租赁经济成本。最后，结合设备的物理属性限制，将

复杂的车联网任务调度问题严谨地抽象为在多重约束下最小化多维加权总开销的长期优化问题，这不仅清晰界定了系统的优化目标，更为后续基于 MDP 的深度强化学习算法设计奠定了坚实的理论模型基础。

第三章 基于 LSTM 与 A3C 的任务卸载算法设计

在高度动态的车联网环境中，复杂的信道衰落与计算资源的随机波动使得传统的启发式算法和静态优化方法难以奏效。DRL 能够通过智能体与环境的持续交互，在未知环境动态的情况下学习最优策略。为了打破传统 DRL 算法因缺乏未来预判能力而导致的策略退化问题，本章提出了一种预测增强的异步优势演员-评论家（PA-A3C）算法。本章将首先介绍 DRL 的理论基础，随后详细阐述车联网任务卸载的马尔可夫决策过程建模，LSTM 预测引擎的网络结构设计，并对比论述基准算法（A3CL）与本文提出的预测增强型算法（PA-A3C）的核心架构与训练机制。

3.1 DRL 背景

强化学习是一种基于试错机制的机器学习范式，其目标是让智能体在与环境的序列决策交互中学习到最大化长期累积奖励的最优策略。该交互过程通常被严谨地建模为马尔可夫决策过程，可用五元组表示：

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{R}, \mathcal{P}, \gamma \rangle \quad (3-1)$$

其中 $\mathcal{S}$ 为状态空间， $\mathcal{A}$ 为动作空间， $\mathcal{R}$ 为奖励函数， $\mathcal{P}$ 为状态转移概率矩阵， $\gamma \in [0,1]$ 为折扣因子。

在任意时刻 t （对应任务序列 i ），智能体观测到状态 $s_i \in \mathcal{S}$ ，依据策略 π 采取动作 $a_i \in \mathcal{A}$ ，随后获得环境反馈的瞬时奖励 r_i ，并转移至下一状态 s_{i+1} 。智能体的优化目标是最大化从当前状态出发的期望累积折扣奖励（即回报 G_i ）：

$$G_i = \sum_{l=0}^{\infty} \gamma^l r_{i+l} \quad (3-2)$$

在车联网任务卸载场景中，由于车辆移动轨迹、无线信道衰落与任务到达率的高度不可预测性，环境的状态转移概率 $\mathcal{P}$ 是完全未知的。在此背景下，无模型强化学习主要分为两大流派：

基于价值的方法：通过深度神经网络拟合状态价值函数 $V_{\pi}(s)$ 或状态动作价值函数 $q_{\pi}(s, a)$ ，该方法在处理离散动作空间时有效，但在面临庞大状态空间时易产生价值过估计。价值函数可以定义为 $V_{\pi}(s) = E_{\pi}[G_i | s_i = s]$ ，它是在策略 π 下从状态 s 开始

的期望累积奖励。价值函数 $V_\pi(s)$ 表示状态 s 有多好，这是本文提出的算法的一部分（即评论家网络）。状态-动作价值函数 $q_\pi(s, a) = E_\pi[G_i | s_i = s, a_i = a]$ 是在策略 π 下，从状态 s 开始并采取动作 a 的期望累积奖励。因此， $V_\pi(s)$ 和 $q_\pi(s, a)$ 之间的关系可以写为 $V_\pi(s) = \sum_{a \in \mathcal{A}} \pi(s, a) q_\pi(s, a)$ 。相应地，RL 算法需要为任意状态求解最优状态价值函数 $V_*(s) = \max_{\pi} V_\pi(s)$ 和最优动作价值函数 $q_*(s, a) = \max_{\pi} q_\pi(s, a)$ 。此外，价值函数可以通过深度神经网络（Deep Neural Network, DNN）来近似，以解决大型状态空间问题。本文假设 θ 是 DNN 的参数，价值函数可以近似为 $V(s, \theta) \approx V_\pi(s)$ 。因此，智能体的目标是找到最佳的 θ 来最小化价值函数。

基于策略的方法：直接通过神经网络参数化策略函数 $\pi_\theta(s, a) = P[a|s, \theta]$ ，通过梯度上升直接优化策略。该方法在处理高维空间和随机策略时表现优异。

为了兼顾两者的优势，本文采用了结合策略梯度与价值估计的演员-评论家（Actor-Critic）架构，并利用异步并行机制进行拓展。

3.2 任务卸载的 MDP 建模与状态空间设计

将车联网计算卸载映射为 MDP 时，动作、状态和奖励的合理设计是决定算法能否收敛的关键。本文在状态空间的设计上，重点区分了传统短视策略与预测增强策略的本质区别。

3.2.1 动作空间 ($\mathcal{A}$)

对于任何到达的待处理任务 i ，Agent 决策中心需要为其制定一条执行路径。动作空间定义为离散集 $\mathcal{A} = \{0, 1, 2\}$ ：

- 1) $a_i = 0$ ：本地车辆执行。无传输时延与越区风险，但受限于本地有限的算力与极高的电池能耗。
- 2) $a_i = 1$ ：MEC 服务器执行。经由 RSU 进行低时延传输，但当车辆高速驶离 RSU 覆盖区时，存在链路断开导致越区失败的致命风险。
- 3) $a_i = 2$ ：云端服务器执行。经由独立的蜂窝网络传输，链路稳定无越区风险，但带宽较窄且需支付云端计算的额外经济成本。

3.2.2 状态空间 ($\mathcal{S}$)

(1) 基准算法 (A3CL) 的局部状态空间:

在缺乏预测辅助的传统方案中, 智能体仅能依赖感知到的瞬时状态进行决策。其状态空间被压缩为一个 7 维向量:

$$s_i^{A3CL} = [q(t), rp(t), d_i, cr_i, g_{mec}^t, g_{cloud}^t, f_{mec}^t] \quad (3-3)$$

其中包含: 任务队列积压量 $q(t)$ 、车辆剩余能量 $rp(t)$ 、当前任务数据量 d_i 与算力需求 cr_i 、瞬时的 MEC 与 Cloud 信道增益 g_{mec}^t, g_{cloud}^t , 以及当前的 MEC 可用资源 f_{mec}^t 。由于缺乏时序深度, 该状态无法表征车辆的移动趋势与未来的网络波动。

(2) 本文算法 (PA-A3C) 的预测增强状态空间:

为了赋予智能体“预判未来”的主动避险能力, PA-A3C 算法通过将全局环境的历史记忆与 LSTM 预测模块的输出深度融合, 构建了 22 维的高维增强状态向量:

$$s_i^{PA-A3C} = s_i^{A3CL} \cup [\widehat{C}_{mec}, \widehat{C}_{cloud}, \hat{\lambda}] \cup [\theta_{mec}, \theta_{cloud}, F_{mec}] \quad (3-4)$$

扩充的维度包括:

- 1) $[\widehat{C}_{mec}, \widehat{C}_{cloud}, \hat{\lambda}]$: 由 LSTM 模块根据时序规律预测的未来 10 个时隙内的 MEC 平均吞吐量、Cloud 平均吞吐量, 以及未来的任务到达率。
- 2) θ_{mec} 与 θ_{cloud} : 过去 5 个时隙的信道增益历史切片 (共 10 维)。
- 3) F_{mec} : 过去 5 个时隙的 MEC 资源波动历史 (5 维)。

3.2.3 综合奖励函数 ($\mathcal{R}$)

智能体的优化目标是最大化累积奖励, 等效于最小化系统长期开销。为了加速收敛并维持梯度稳定, 本文将系统开销进行了负向映射, 设定了严格的优劣边界。任务 i 的瞬时奖励 r_i 如下:

$$r_i = \begin{cases} -v\{F\}, & \text{if handover.} \\ -v\{\xi_1\Psi(n, i) + \xi_2\Omega(n, i) + \xi_3Y(n, i) + \eta P^T(n, i) + \psi P^F(n, i)\}, & \text{else.} \end{cases} \quad (3-5)$$

基于物理系统的真实标定, 惩罚缩放因子 $v = 0.01$; 越区惩罚常数 $F = 8.0$ (即产生 -0.08 的极大负奖励); 系统开销的权重分别设为: 时延 $w_t = 0.5$ 、能耗 $w_e = 0.4$ 、经济成本 $w_c = 0.1$ 。该奖励权重的设计使得在 MEC 覆盖边缘, 选择云端卸载的安全奖励远高于试图在 MEC 冒险的数学期望, 从而通过强化学习惩罚机制倒逼智能体学会规

避越区。

3.3 LSTM 网络结构设计

在将预测状态 S_{pred} 输入强化学习智能体之前，系统首先需要在云端系统仿真环境中运行高保真的时序预测模型。由于车联网的信道多普勒频移和算力波动具有强时间相关性，本文采用了长短期记忆网络作为预测引擎的核心架构。

与传统循环神经网络（Recurrent Neural Network, RNN）相比，LSTM 引入了细胞状态与三个精密的门控结构（遗忘门、输入门、输出门），能够有效解决长序列训练过程中的梯度消失问题，从而精准提取信道衰落的隐式周期性规律。

在代码工程实现中，针对 MEC 吞吐量、Cloud 吞吐量及任务到达率三个独立的时间序列特征，本文分别构建了三个并行的 LSTM 网络模块，如下图 3-1 所示。




图 3-1 LSTM 逻辑架构

在整个 LSTM 架构中，每个 LSTM 预测器的具体超参数与网络层设计如下：

输入层（Input Layer）：接受特征维度为 $input_size=1$ 的滑动窗口序列，输入序列长度（即回顾的历史时隙数）设定为 50 步。输入张量形状为 $[Batch_Size, 50, 1]$ 。

隐藏层（Hidden Layers）：采用 $num_layers=2$ 的双层堆叠 LSTM 结构，每层的隐藏单元数设定为 $hidden_size=64$ 。该规模在确保足够特征提取能力的同时，保证了实时推断的低延迟要求。

全连接输出层（FC Layer）：LSTM 最后一层的输出隐藏状态 h_t 送入一个线性全连接层，输出维度设定为 1，代表对未来特定窗口期（如未来 10 个时隙）的预测均值。

该预测引擎通过离线采集的大规模物理仿真数据集进行有监督预训练，均方误差（Mean Squared Error, MSE）损失函数采用 Adam 优化器进行梯度下降。

3.4 深度网络架构与 A3C 训练机制

在面对包含 22 维连续特征的庞大状态空间时，DQN 等单线程算法容易陷入经验回放池的过拟合，且收敛极慢。为此，本文采用 A3C 并行训练架构。

3.4.1 Actor-Critic 双网络结构

在 A3C 架构中，智能体内部包含两个独立但协同工作的多层感知机（Multilayer Perceptron, MLP）：

策略网络（Actor, $\pi_\theta(a|s)$ ）：输入层接收 22 维预测增强状态，隐藏层负责特征降维与提取，输出层采用 Softmax 激活，输出当前状态下采取 3 种卸载动作的概率分布。

价值网络（Critic, $V_{\theta_v}(s)$ ）：网络结构与 Actor 类似，但输出层为单一线性神经元，用于估算处于当前状态 s_i 所能带来的期望累积折扣奖励。

3.4.2 异步梯度更新机制

为了打破强化学习中时序样本的强相关性，PA-A3C 算法在训练阶段摒弃了传统的经验回放池，转而采用一主多从的异步多线程架构。

在本文的系统配置中，初始化了 1 个全局共享网络（Global Network）以及 $N = 5$ 个相互独立的工作线程网络（Worker Networks）。每个 Worker 在环境初始化时被赋予不同的随机种子（Seed=10, 20, 30, 40, 50），从而在不同的随机交通流与信道衰落场景中并发探索。

算法通过多步时间差分法计算优势函数 $A(s_i, a_i)$ ，以指导策略更新。设全局网络同步步长为 $m = 20$ ，第 i 步的 m 步目标价值 R_i 为：

$$R_i = \sum_{k=0}^{m-1} \gamma^k r_{i+k} + \gamma^m V_{\theta_v}(s_{i+m}) \quad (3-6)$$

(1) Critic 网络的均方误差更新:

Critic 的目标是使其预测价值尽可能贴近真实回报 R_i 。其损失函数与参数更新公式为:

$$L_c(\theta_v) = \frac{1}{2} \sum_t (R_i - V_{\theta_v}(s_i))^2 \quad (3-7)$$

$$\theta_v \leftarrow \theta_v + \alpha_c \nabla_{\theta_v} L_c(\theta_v) \quad (3-8)$$

其中 $\alpha_c = 1 \times 10^{-4}$ 为学习率。

(2) Actor 网络的策略梯度更新:

Actor 网络沿着优势函数 $A(s_i, a_i) = R_i - V_{\theta_v}(s_i)$ 的方向进行梯度上升。若 $A > 0$, 说明当前动作优于平均表现, 应增加其概率。同时, 为防止智能体过早收敛 (例如保守地永远卸载到云端), 引入策略熵 $H(\pi_\theta)$ 作为正则化项以鼓励探索:

$$\nabla_\theta J(\theta) = \nabla_\theta \log \pi_\theta(a_i | s_i) A(s_i, a_i) + \beta \nabla_\theta H(\pi_\theta(s_i)) \quad (3-9)$$

$$\theta \leftarrow \theta + \alpha_a \nabla_\theta J(\theta) \quad (3-10)$$

其中, 熵正则化系数 $\beta = 0.01$, 策略网络学习率 $\alpha_a = 1 \times 10^{-4}$ 。

在训练过程中, 各工作线程每探索 20 步, 便异步地将累积梯度推送到全局网络, 并从全局网络拉取最新的参数进行下一轮探索。这种高并发的探索与预测辅助的高维状态输入相结合, 确保了 PA-A3C 算法能够在极其复杂的车联网计算卸载问题中, 高效且稳定地搜寻到全局最优调度策略。

3.5 本章小结

本章详细阐述了基于 LSTM 与 A3C 架构的车联网任务卸载算法 (PA-A3C) 的设计与建模过程。首先, 针对车联网高动态、强时变的特性, 将任务卸载问题严谨地抽象为最小化系统综合开销的马尔可夫决策过程。在状态空间的设计上, 创新性地打破了传统基准算法仅依赖局部瞬时状态的短视局限, 将 LSTM 模块对未来的预测信息与历史时序切片进行深度融合, 构建了高维的预测增强状态空间。其次, 详细说明了用于精准预测 MEC 吞吐量、云端吞吐量及任务到达率的 LSTM 网络隐藏层及输出层结构设计。最后, 提出了预测增强型 PA-A3C 算法的双网络架构, 并深入剖析了其主多从的异步多线程梯度更新机制。该算法设计从根本上克服了传统深度强化学习在高维连续状态空间

下采样效率低下的缺陷，赋予了智能体感知历史与预判未来的能力。

第四章 预测辅助仿真系统设计与实现

为了验证本文所提的理论模型与 PA-A3C 算法的有效性，本文基于 Python 3.10 编程语言与 PyTorch 深度学习框架，自主开发了一套高保真的车联网事件驱动仿真平台。本章将详细阐述该平台的总体架构设计、物理层对象的面向对象建模、LSTM 预测辅助融合机制以及异步多线程的底层交互逻辑。

4.1 仿真平台总体架构与运行机制

本文设计的仿真平台遵循“高内聚、低耦合”的软件工程原则，实现了物理世界模拟、LSTM 预测状态聚合与智能体决策的严格分层。系统整体代码架构由以下三大核心层级构成，具体架构示意图见下图 4-1 所示。




图 4-1 仿真系统架构

- 着眼于整个仿真平台，对于具体架构描述如下：
1. 物理环境层：该层负责高精度地模拟物理世界中实体的运动学特征与电磁波传播特性。包含了车辆模型（Vehicle）、MEC 服务器模型（MecServer）、云服务器模型（CloudServer）以及无线信道衰落模型（Channel）。
 2. LSTM 预测层：以系统环境和 LSTM 预测引擎为核心。该层负责实时采集物理层的时序切片，利用训练好的 LSTM 引擎进行特征提取与未来演进推理，最终构建出

包含 22 维特征的高保真预测增强张量。

3. 强化学习决策层：以基于 PyTorch 构建的 ActorCritic 神经网络为决策大脑，通过多进程实例化多个 Worker，在系统环境中并发执行动作采样、优势函数计算与梯度反向传播。

系统的运行机制采用离散时间步驱动。在主逻辑循环的每一个时间步 t 中，仿真平台按顺序执行“状态感知→LSTM 预测→决策动作下发→物理状态更新→奖励计算”的闭环流水线。

4.2 物理层底座的面向对象建模与实现

为了在代码中实现复杂的车联网数学模型，本文采用面向对象的思想，对物理实体进行了精细化建模。

4.2.1 车辆实体与动态任务生成引擎

在 Vehicle 的设计中，本文封装了车辆的物理属性与计算属性。车辆对象初始化时被赋予 10 m/s 的恒定速度与 2.0 GC/slot 的本地 CPU 计算频率。

为了模拟车联网中突发性极强的计算负载，系统并未采用简单的静态任务序列，而是专门设计了基于一阶马尔可夫链的动态任务生成引擎。在具体实现中，任务到达率 λ 被维护为一个状态转移矩阵，每隔 20 个时隙发生一次状态跃迁。在每一时隙初，车辆根据当前的 λ 触发泊松过程，生成具体的 Task 对象。每个 Task 实例包含了随机生成的数据量大小（0.1 ~ 2.5 MB）与算力需求（1.0 ~ 10.0 GC），并被压入车辆的本地缓存队列中等待调度。

4.2.2 Jakes 多普勒信道演进模块

信道模块是体现车辆高动态特性的关键。为了避免传统静态信道模型带来的仿真失真，本文在代码中严格实现了 Jakes 衰落模型。

在系统环境的每一次 step() 推进的过程中，信道模块首先根据车辆的 X 坐标计算其与最近 RSU 之间的欧氏距离，进而更新大尺度路径损耗。同时，系统内部维护了一个复数域的随机变量，利用公式 $h(t) = \kappa h(t-1) + \sqrt{1 - \kappa^2} \cdot e(t)$ 更新小尺度衰落系

数。其中，时间相关系数 κ 由设定的载波频率与车辆速度严格计算得出。这种基于时序迭代的信道生成代码，确保了信道增益矩阵在时间轴上呈现出平滑且符合物理规律的正弦波动态势。

4.3 系统仿真环境的核心调度逻辑

预测增强型系统仿真环境是仿真系统的核心枢纽，它不仅继承了基础物理环境的更新逻辑，更承担了“全局维护”与“状态扩维”的重任。在 OpenAI Gym 规范的基础上，本文重写了其核心的 `step(action)` 与 `reset()` 接口。

4.3.1 高维状态的拼接与张量化

在传统的环境代码中，状态往往是一个简单的字典或低维数组。而在预测增强型系统仿真环境中，状态提取是一个复杂的特征工程过程。具体实现包含以下三个步骤：

1. 局部瞬时状态的提取：读取车辆对象的当前电量、队列积压量以及任务相关参数，构成 7 维基础状态。
2. LSTM 预测流的嵌入：环境维持一个长度为 50 的滑动窗口，用于缓存历史信道增益。在状态提取时，将该滑窗转化为 PyTorch 张量，并送入加载了预训练权重的 `ThroughputPredictor` 和 `TaskArrivalPredictor` 模型中进行前向传播，最终输出 3 维未来预测状态。
3. 时序历史切片的提取：提取过去 5 个时隙的 MEC 资源可用情况、无线信道增益等历史特征。

最终，系统将上述不同维度的特征严格按序拼接为一个 22 维的预测增强型状态空间，并将其返回给强化学习智能体用以学习和训练。这种底层的张量拼接机制，赋予了智能体“洞察过去、预知未来”的全局视野。

4.3.2 越区中断与物理开销的代码级结算

`step(action)` 接口负责执行动作并计算瞬时奖励。在奖励结算代码中，本文严格区分了不同的卸载决策：

对于越区风险的判定机制：当动作 $a = 1$ （MEC 卸载）被触发时，系统首先进入

一个内部的检测判定循环，模拟数据包在时隙内的分片传输。在此循环中，会实时监控车辆的当前位置坐标 $veh.x$ 。如果检测到 $veh.x$ 超出了当前 RSU 的覆盖半径，系统将立即触发中断异常，并触发系统环境信息字典中相关参数的修正和标记，同时返回一个包含极端惩罚值（ $-8.0 \times$ 缩放因子）的奖励值。

对于时延与能耗的精确累计：当成功传输的任务时，会根据 $E = P_{tx} \times T_{tx}$ 累加射频能耗，并结合算力节点的频率累加执行时延。最终，通过加权系数矩阵 $\xi = [0.5, 0.4, 0.1]$ 将多维开销标量化为负向奖励反馈给智能体。

4.4 A3C 并行训练引擎的底层实现

由于 22 维连续状态空间极其庞大，传统的单线程 DQN 在本文的仿真环境中极易陷入内存溢出或数据高度相关导致的收敛停滞。因此，本文利用 PyTorch 的 `torch.multiprocessing` 库，从底层开发了基于异步多线程的交互引擎。

4.4.1 共享内存优化器与并发拓朴

在主进程中，系统会构建一个全局的 ActorCritic 神经网络，并自定义了 SharedAdam 优化器。该优化器通过重写内部状态，调用相关访存接口，将其梯度步数和指数移动平均状态长期驻留在操作系统的共享内存中，确保多个工作线程能够安全地并发写入。

随后，系统将会挂载 18 个完全独立的 Worker 进程。每个 Worker 在初始化时，不仅被分配了独占的预测增强型系统环境，还被赋予了既定且递增的基础随机种子（Seed = 10, 20, 30...）。这一设计确保了不同线程中的车辆会遭遇截然不同的马尔可夫任务流与信道噪声，极大地丰富了经验池的样本多样性。

4.4.2 梯度异步回传与网络同步

在 Worker 的运行主循环中，不使用传统的经验回放池，而是维护临时的 `buffer_s, buffer_a, buffer_r` 列表。优势计算采用 N-Step 的方式，当局部线程探索满 $t_{max} = 20$ 步时，停止交互。代码通过对相关列表的反向遍历，利用贝尔曼方程逆向推导每一个时间步的真实折扣回报 R 。

对于损失重构与梯度裁剪的处理，累计的 TD-Error 将会被转化为 Critic 的均方误差

损失，结合了策略熵的对数概率将会被转化为 Actor 损失。调用损失反馈接口，计算局部梯度后，为了防止高动态惩罚值引发的梯度爆炸，代码强制执行了切片归一化操作，将全局网络的梯度范数严格限制在 5.0 以内。

异步更新全局权重后，将会清空局部缓存信息，并利用 `load_state_dict()` 接口将全局最新参数硬拷贝至局部网络以完成参数拉取，开启下一轮试错。

综上所述，本文在代码层面实现了从底层物理信道演进，到 LSTM 预测状态重构，再到高并发强化学习优化的完整数据链路，为后续的算法性能验证提供了坚实、可靠的工程仿真平台。

4.5 本章小结

本章重点介绍了预测辅助车联网仿真系统的总体架构设计与底层代码实现逻辑。为了验证前述理论模型与 PA-A3C 算法的有效性，本文自主开发了一套事件驱动的高保真车联网仿真平台。首先，规划了包含物理环境层、LSTM 预测层与 DRL 决策层的三层系统运行机制，实现了物理模拟与智能决策的严格分层。其次，采用面向对象思想对物理层底座进行了精细化建模，成功实现了马尔可夫链驱动的动态任务生成引擎以及严谨的 Jakes 多普勒信道演进模块。随后，阐明了仿真环境的核心调度枢纽逻辑，详述了高维预测状态的张量化拼接方法，以及越区中断异常与各项物理开销的代码级结算机制。最后，深入探讨了 A3C 并行训练引擎的底层多进程实现细节，包括共享内存优化器的并发拓扑设计与异步梯度回传机制，为后续的算法性能验证提供了坚实、高并发的工程基础。

第五章 仿真实验与结果分析

本章将详细介绍基于 Python 与 PyTorch 深度学习框架搭建的仿真环境及核心参数设置，并从 LSTM 预测模块精度、强化学习算法收敛性以及多场景综合性能三个维度，对本文提出的 PA-A3C 算法与传统基准算法进行详实的测试、对比验证和剖析。

5.1 仿真环境与参数设置

为了真实还原车联网的高动态环境，本文基于离散时间事件步搭建了物理仿真环境（SystemEnv）与预测增强环境（DTSystemEnv）。系统在完全同步的时隙下运行，时隙长度设为 $T = 0.2$ s。车辆以 10 m/s 的恒定速度行驶，沿途每隔 50 m 部署一个配备 MEC 的 RSU。

在通信链路方面，MEC 专网与 Cloud 蜂窝网络的带宽分别设定为 10 MHz 和 6 MHz，车辆恒定发射功率为 1.25 W，信道衰落采用涵盖路径损耗与多普勒频移的 Jakes 模型。在计算资源方面，考虑到不同设备的架构差异，本地车辆、MEC 服务器及云端服务器的单时隙计算能力分别设为 2.0 GC/slot、5.0 GC/slot（均值）和 20.0 GC/slot。

此外，为了构建合理的动作生态位，本文对成本权重及惩罚机制进行了精细化标定。具体关键的仿真参数如下表 5-1 所示。

表 5-1 仿真参数

参数名称	符号	取值
MEC 信道 / Cloud 蜂窝带宽	B_{MEC} / B_{Cloud}	10 MHz / 6 MHz
车辆发射功率 / 噪声功率	p_{tx} / σ^2	1.25 w / -20 dBm (10^{-5} w)
任务数据量 / 计算量服从区间	d_i / cr_i	[0.1,2.5] MB / [1,10] GC
本地计算能耗系数	ζ / τ	0.5 / 3.0
云端计算租赁单价 / 传输单价	$\overline{\omega_{ex}} / \overline{\omega_{tx}}$	0.05 / 1.6
时延 / 能耗 / 经济成本权重	$w_t / w_e / w_c$	0.5 / 0.4 / 0.1
越区中断基础惩罚值	F	8.0

依托上述的参数集，系统形成了一个清晰的生态位和博弈空间：当车辆处于 RSU 覆盖中心时，MEC 凭借宽带低时延成为最优解；当车辆驶近 RSU 边界（越区中断概率剧增至大约 70%以上）时，巨大的惩罚期望将促使最优解切换至独立的 Cloud 链路；而当任务计算量相对较小且体积较大时，本地计算也能发挥一定的作用。

5.2 基准方法

全部本地执行（AL）：在此场景中，所有任务都在本地车辆上执行。

全部卸载到 MEC（AM）：在任何状态下，无论无线条件和 MEC 服务器的计算资源如何，所有任务都卸载到 MEC 服务器执行。

全部卸载到云端（AC）：与 AM 类似，所有任务都卸载到云服务器执行，无论无线条件和使用云端的租赁成本如何。

随机选择（RC）：以相同的概率随机选择三个计算单元（即本地车辆、MEC 服务器和云端）之一来执行任务。

本地车辆中的 A3C（A3CL）：与本文的方案不同，A3CL 的调度模块（即 DRL 智能体）部署在本地车辆中。在此场景中，由于缺乏全局信息，车辆只能根据当前状态信息（例如，当前信道信息和 MEC 状态）做出卸载决策。此方法用于展示本文的算法在没有 LSTM 预测辅助情况下的性能。

5.3 LSTM 预测评估

5.3.1 LSTM 真实值与预测值的比对机制

系统环境需要为决策中心提供高保真的预测引擎。本文首先在物理仿真环境中通过随机游走策略运行数千个 Episode，游走过程中将会自动采集车辆的历史轨迹与网络状态，并依此构建了专门用于 LSTM 预测训练的离线数据集。

在评估预测精度时，本文采用了滑动窗口机制。对于时隙 t ，测试脚本从环境缓存（离线数据集）中提取过去 50 个时隙的对数信道增益作为 LSTM 的输入特征；而对应的“真实值”，则是物理引擎根据未来真实演进轨迹，严格计算出的未来 10 个时隙内的平均香农吞吐量。

引入 LSTM 预测辅助的核心价值在于打破单车视角的信息盲区。仿真记录表明，车辆与最近 RSU 的物理距离呈现周期为 5 秒的锯齿形波动，导致 MEC 无线吞吐量从中心的 80 ~ 100 Mbps 锐减至边缘的 10 Mbps 左右，同样基于香农定理，Cloud 无线吞吐量的变化趋势也呈现出相似的波动情况，具体系统环境的波动检测情况，如下图 5-1 所示。




图 5-1 系统环境的检测

5.3.2 预测性能分析

在自建的系统环境中，通过预先对系统环境中的时序信息进行采样工作，采集大量物理仿真数据集，其中数据集包含 MEC 信道增益、Cloud 信道增益和任务到达率三种时序信息，依据前述所收集的时序信息，分别独立训练了三个基于长短期记忆网络的 LSTM 网络预测器。训练效果如下图 5-2 所示，训练曲线中，实线表示训练集的损失变化，虚线表示验证集的损失变化。可以发现，针对于 MEC 吞吐量、Cloud 吞吐量和任务到达率的三个 LSTM 预测器的均方误差(MSE)均在约 10 个 Epoch 内快速收敛至 10^{-3} 数量级，且无过拟合现象。




图 5-2 LSTM 训练损失曲线

将训练好的模型在独立的测试集中进行预测重建，可以观察到由于车辆往复穿越 RSU，造成吞吐量成周期性的正弦波动。如下图 5-3 所示，在 LSTM 预测模块中，尤其在 MEC 吞吐量预测上，LSTM 输出的预测曲线（蓝色虚线）与真实物理正弦波动（橙色实线）的贴合度极高。其平均绝对误差 (Mean Absolute Error, MAE) 仅为 0.4082 MB/s；相较于传统基准算法 (A3CL) 仅采用当前瞬时值作为静态估计，LSTM 使预测精度大幅提升至 89.68%。




图 5-3 MEC 吞吐量的真实/预测值比对

在 LSTM 预测模块中，云端的吞吐量预测也展现出极高的跟踪精度，如下图 5-4 所示。云端信道吞吐量的预测曲线（绿色虚线）与真实物理正弦波动（红色实线）的 MAE 达到了 0.5206 MB/s，预测的精度达到了 81.28%。




图 5-4 Cloud 吞吐量的真实/预测值比对

此外，任务的到达率的预测值与真实值的比对同样呈现出较高的贴合度，如下图 5-5 所示。任务的到达率将会决定任务来临的强度，在不同时间段，任务到达率可能不同。例如，车辆在急刹车时接收的任务比慢速行驶时多。假设在马尔可夫链中，任务的到达率每 20 个时隙将会随机游走进行变动。在前述的系统环境设定下，任务到达率的预测精度可以达到 94.72%。




图 5-5 任务到达率的真实/预测值比对

5.4 强化学习算法的训练与收敛性分析

强化学习采用并行训练的方式，为消除单一随机网络初始化带来的偶然偏差，本文对 A3CL 与 PA-A3C 分别设置了 5 组不同的随机种子（Seed=10, 20, 30, 40, 50）独立开展训练。训练过程设置总回合数 5000 Episode，每回合最大执行步数为 200 steps，各异步线程每探索 20 步即与全局网络同步一次梯度信息。

5.4.1 奖励设计与动作生态位博弈分析

算法能否向最优策略收敛，极大程度上取决于奖励函数的边界设计。在本文的真实物理量级设定下，由于越区失败惩罚参数 F 的设定，系统内形成了一个严苛的惩罚悬崖。具体而言，当车辆处于 MEC 安全覆盖区时，正常完成任务的期望奖励最高；而当车辆处于 RSU 边缘交界区（越区概率高）时，若强行选择 MEC，其面临的期望惩罚将增大，此时选择无越区风险的 Cloud 链路将具备较高的效用优势。这一精细的生态位设计，正是驱动 LSTM 预测辅助的智能体学会在边界处主动切换链路的底层数学动力。

5.4.2 策略探索与综合奖励收敛评估

如下图 5-6 所示，在包含方差阴影的归一化奖励对比图中，可观察到在训练初期（0 ~ 1000 Episode），两种算法均处于剧烈的随机探索阶段，累积奖励处于较低水平。然而，在迭代约 1000 轮后，PA-A3C 算法的性能曲线开始产生突破，并持续且稳定地超越 A3CL。在训练的最后 200 个 Episode，PA-A3C 的折合奖励收敛区间为 $[-1.9809, -1.9154]$ ，相较于 A3CL 的 $[-2.4031, -2.0306]$ ，系统总效用大幅提升了约 12.12%。

值得深度剖析的是图中曲线的方差阴影宽度，A3CL 曲线的阴影较宽，反映出其强烈的策略不稳定性，由于状态空间仅有 7 维，A3CL 对未来的越区风险一无所知，智能体的收敛轨迹高度依赖于早期的随机探索经验，在多次遭受越区惩罚后，其某些随机种子的策略可能均保守地崩塌至各不相同的次优解。

反观 PA-A3C，其曲线阴影显著更窄且平滑，表明在庞大且复杂的 22 维预测增强型状态空间下，不同的随机种子探索出了各具特点但均处于高效能区间的局部最优协同策略，展现出了更强的策略多样性与环境适应力。这强有力地证明了 LSTM 预测模块

提供的对未来信道状态与越区风险的确定性预判，一定程度上，有效抹平了环境的随机噪声，并展现出了卓越的算法鲁棒性与策略泛化能力。




图 5-6 A3C 训练曲线

5.4.3 任务时延优化的分析

训练期间的时延记录，见下图 5-7 所示，PA-A3C 的平均任务时延从约 1000 Episode 起便持续脱离 A3CL 的基线。在最终收敛阶段，PA-A3C 的平均时延收敛区间为 $[0.7583, 0.7719]$ s，相较于 A3CL 的 $[0.7788, 0.8632]$ s，降低了约 6.10%。这一时延优势的本质在于对 MEC 资源的精准利用：由于 MEC 分配的带宽 (10 MHz) 远宽于 Cloud 的蜂窝带宽 (6 MHz)，在同等数据量下 MEC 的传输时延更短；PA-A3C 借助 LSTM 预判出安全的通信窗口期，果断大量选择 MEC (占比达 66.1%)，从而成功避免了 A3CL 因盲目惧怕越区而将所有任务推向较慢 Cloud 链路或本地执行所产生的额外延迟。




图 5-7 训练阶段的时延性能

5.4.4 通信系统能耗的隐性降低

训练期间的能耗记录,见下图 5-8 所示,进一步揭示了决策路径对物理硬件的影响。PA-A3C 的平均能耗的收敛区间为 $[1.1122, 1.2040]$ J, 较 A3CL 的 $[1.1880, 1.2473]$ J 降低了 4.89%。虽然两者都极少选择高耗能的本地计算 (Local), 但 A3CL 高度依赖的 Cloud 链路由于带宽较窄, 导致车辆射频发射模块 (发射功率恒定为 1.25 W) 需要维持更长的开启时间才能完成数据上行。而 PA-A3C 智能选择信道处于峰值状态的 MEC 链路, 往往只需较少的时隙即可完成传输。因此, LSTM 预测增强的前瞻性调度不仅优化了宏观的时延体验, 更从微观物理层面缩短了射频工作时间, 有效提升了车载设备的续航能力。




图 5-8 训练阶段的能耗性能

5.5 多场景综合评估

在评估阶段，测试环境关闭了探索噪声（采用 argmax 取值），并引入了全部本地执行（All Local）、全部 MEC 执行（All MEC）、全部云端执行（All Cloud）以及随机分配（Random）四种静态基线策略，开展了三种不同维度的测试。

5.5.1 场景 A：马尔可夫动态负载标准测试

该场景完全模拟真实的动态环境，任务到达率 λ 遵循 $\{0.1, 0.3, 0.5, 0.7, 0.9\}$ 的状态空间，每 20 个时隙进行一次马尔可夫随机跃迁。

在决策分布上，见如下图 5-9 所示，A3CL 只有 7 维的状态空间，无法预测信道趋势，将其 66.9% 的任务的卸载方式保守的退化为 Cloud 处理；而 PA-A3C 拥有 LSTM 预测的 22 维状态空间，可提前感知信道增益趋势与 RSU (MEC) 的相对位置。将 66.1% 的任务卸载至 MEC，27.1% 卸载至 Cloud。这直接印证了 LSTM 预测辅助的主动避险能力：当预测到安全时果断用 MEC，预测到越区危险时提前切 Cloud。




图 5-9 动态负载测试中的决策分布

在宏观指标上，如下图 5-10 所示，PA-A3C 实现了 0.7721 s 的平均时延与 0.7233 J 的平均能耗，权衡之下，全面优于其他基准算法。对比之下，All Local 策略虽然时延极低，但能耗高达 2.5836 J，正是此高能耗性造成了其并不具备实用性；而 All MEC 策略看似能耗最低，但因频繁因越区中断风险而断流，时延恶化至 1.0837 s。




图 5-10 动态负载测试中的时延、能耗对比

5.5.2 场景 B：静态队列扫描（压力测试）

为专门评估算法应对突发庞大计算任务时的队列调度效率，本条设计了静态队列扫描实验。测试时预先向环境注入 20 至 100 个不等的初始任务，并同时冻结新任务的生成。测试结果见下图 5-11 所示，结果表明，随着预填充队列深度的增加，All MEC 与 Random 等基准算法的时延相较于 PA-A3C 发生明显劣化，All MEC 在静态负载下表现

最差，预填充更多任务时越区失败的概率不变，说明 MEC 的劣势是结构性的（RSU 覆盖边界问题）；而 PA-A3C 由于能结合 LSTM 对未来网络资源的超前预判进行合理分流，其平均处理时延不仅保持稳定领先，且稳定维持在 $0.770 \sim 0.778$ s，展现出极强的抗并发压力能力，具有良好的泛化性。PA-A3C 相对于 A3CL 的优势明显，体现了预测辅助决策本身的优势。




图 5-11 静态队列扫描测试

5.5.3 场景 C：恒定负载下的动态时序追踪

为了排除任务到达率随机游走对结果观测的干扰，于是开展了恒定负载的相关测试。设定任务到达率常数 $\lambda = 0.5$ ，同时保留所有的信道衰落与车辆移动物理特性，记录 200 个 Step 中的每步累积平均时延。

时序追踪曲线如下图 5-12 所示，在早期阶段（step 0~50），所有算法的累计均值从高处（约 $0.8 \sim 1.6$ s）快速下降，其中 PA-A3C 的阴影带（置信区间）明显窄于 A3C 和 Random，说明预测辅助状态的感知使得决策更加稳定；三条核心曲线在 50 步后均实现平滑分离，并进入收敛阶段，PA-A3C 稳定在约 0.7721 s 的最低水平；而 Random 逐渐收敛至 0.8909 s 的水平，说明随机策略的不确定性持续存在；反观 A3CL 逐渐收敛至 0.8293 s 的水平，介于 Random 与 PA-A3C 两条曲线之间。比对曲线的间距在 step

100 之后保持稳定不变，说明 PA-A3C 的优势不是偶然的早期波动，而是策略层面的结构性差异；不同 seed 下 PA-A3C 的行为高度一致，证明 LSTM 预测模块提供了稳定的信息增益，从时间序列的持续性上彻底验证了预测增强机制的有效性。




图 5-12 恒定负载测试

5.6 本章小结

本章对本文构建的仿真环境与所提出的 PA-A3C 算法进行了全方位、多场景的仿真实验与结果剖析。首先，设定了高保真车联网环境的核心物理参数，并定义了五种不同的基准卸载策略以供对比评估。在 LSTM 预测模块的性能验证中，实验数据表明本文训练的预测器在极短的时间内快速收敛，实现了对网络吞吐量及突发任务到达率的高精度前瞻性预测，成功打破了单车视角的信息盲区。在强化学习算法的收敛性分析中，PA-A3C 算法展现出远超基准算法 A3CL 的收敛速度与策略稳定性，系统总效用大幅提升了约 12.12%，并从物理层面有效降低了平均任务时延与通信系统能耗。最后，通过马尔可夫动态负载测试、静态队列扫描压力测试以及恒定负载时序追踪等多场景综合评估，充分证实了 PA-A3C 算法在应对复杂、突发车联网环境时，具备卓越的主动避险机制、极强的抗并发压力能力以及优异的鲁棒性。

结论与展望

随着车联网与自动驾驶技术的蓬勃发展，车载终端的算力瓶颈与低时延应用需求之间的矛盾日益凸显。将计算密集型任务卸载至移动边缘计算服务器是破局的关键。然而，车辆的高速移动性导致的信道剧烈衰落与越区切换中断，使得传统的静态卸载调度策略面临失效风险。针对这一行业痛点，本文跳出了传统“基于瞬时状态进行被动响应”的决策框架，创造性地提出了一种基于 LSTM 预测辅助与异步深度强化学习（A3C）相结合的主动式任务卸载机制。

纵观全文，本文的创造性工作与创新见解主要体现在以下三个维度：

第一，实现了从“被动试错”到“主动预判”的范式转移。传统的强化学习算法（如本文的基准算法 A3CL）由于缺乏历史视野，面对未知的越区断连惩罚往往表现出严重的“策略退化”——即为了规避风险而极端保守地将任务全部推向高延迟的云端。本文构建了基于 LSTM 网络的高保真预测核心，深度挖掘了过去时序信道增益中隐含的多普勒频移与路径损耗规律。该机制使得预测精度有了相对较高的提升，成功地将物理世界中不可见的“未来越区风险”与“资源波动趋势”映射为智能体可读取的高维数字特征，彻底打破了单车视角的短视局限。

第二，构建了高度契合车联网物理特性的多维成本博弈模型。本文严谨地量化了本地、边缘与云端三类异构算力的生态位特征。通过将极端的越区惩罚与时延、能耗及经济成本相融合，构建了一个具备明确优劣边界的 MDP。研究深刻揭示了在复杂动态网络中，并不存在绝对最优的单一算力节点：MEC 是高收益伴随高风险的低延迟首选，而云端蜂窝网络则是规避物理越区边界的安全选项。这种精细的数学建模为智能体学习的精细化协同策略奠定了理论基础。

第三，验证了在高维连续状态之下 PA-A3C 算法的卓越收敛性与鲁棒性。面对包含系统环境历史与预测信息的 22 维庞大状态空间，单线程强化学习极易陷入维度灾难。本文引入的异步优势演员-评论家（A3C）并行探索机制，有效打破了时序样本的强相关性。大量且详实的仿真结果有力证明，PA-A3C 算法不仅彻底克服了策略退化问题，使智能体能够灵活统筹本地、边缘与云端资源，更在马尔可夫动态负载与静态并发压力测试中，全面实现了时延（性能提升约 7.56%~8.73%）与能耗（降低约 2.03%）的双

重极致优化，系统综合效用跃升 12.12%。

综上所述，本文的研究成果不仅为高动态车联网环境下的时延敏感型任务调度提供了一套高效、稳健的算法解决方案，也从理论与实践双重层面证实了“LSTM 预测辅助+深度强化学习”架构在未来 6G 通信与泛在算力网络中的巨大应用潜能。

尽管本文在 LSTM 预测辅助赋能的车联网任务卸载领域取得了实质性的优化成果，但真实道路交通与无线通信环境的复杂程度远超理论模型。受限于研究周期与现有算力平台，本文的工作仍存在诸多可待完善之处。在后续的研究中，建议从以下四个前沿方向展开深入探索与改进：

（1）从单智能体决策向多智能体复杂博弈拓展：本文当前的 MDP 建模主要站在单车视角（或多个独立并行的单车视角），假定系统资源主要由环境状态被动反馈。但在交通流密集的真实路口，大量车辆会同时竞争有限的 RSU 信道带宽与 MEC CPU 资源，单车的最优解可能会导致全局的拥塞崩溃。未来的研究可引入多智能体近端策略优化或多智能体深度确定性策略梯度算法。通过在云端数字孪生中心建立集中式的 Critic 网络来评估全局状态，在车端部署分布式的 Actor 网络执行决策，从而在竞争环境下寻找算力分配的纳什均衡。

（2）引入车对车拓扑的自组织协同算力网络：目前的卸载路径仅局限于“车-路”和“车-云”两种垂直通信模式。随着车载计算单元算力的不断提升，路面上闲置的对向行驶车辆或同向伴随车辆完全可以作为临时的“移动边缘微云”。后续方案可尝试引入车对车通信链路，利用图神经网络对高度动态的车辆拓扑图（如车辆间距、相对速度、链路存活期）进行拓扑特征提取，实现任务在车流网络内部的横向自组织流动，以进一步降低对固定基础设施的依赖。

（3）基于微观交通流模拟器的混合高保真仿真：本文的物理仿真设定车辆以 10 m/s 的恒定速度沿直线单向行驶，这在一定程度上抽象并简化了物理世界的复杂度。现实城市路网中充斥着红绿灯启停、车道变换、加减速以及突发拥堵等复杂行为，这些微观行为将直接引发多普勒频移的非线性剧变与任务到达率的极端长尾效应。未来的方案改进应当引入 SUMO（Simulation of Urban MObility）等专业的微观交通流仿真器，将其与现有的 Python 通信计算仿真器进行联合部署，在更加极端和真实的非稳态交通流中锤炼强化学习智能体的鲁棒性。

(4) 仿真系统自身的开销评估与轻量化研究：本文假定云端全局信息维护模块能够无代价地获取车辆的历史状态并实时运行 LSTM 预测。然而，在真实工程部署中，高频的状态同步上报（如信道 CSI 信息、电池电量）本身就会消耗大量的上行带宽与终端电量；同时，云端维持海量全局信息也面临巨大的算力开销。因此，后续研究有必要将仿真系统自身的运行开销纳入 MDP 的综合目标函数中。通过探索基于事件触发的自适应状态同步机制，或利用联邦学习与网络剪枝技术实现预测模型的端侧轻量化部署，从而真正走向商业化落地的闭环。

致 谢

本论文的撰写与相关代码的仿真工作已告一段落。回首数月来的研究历程，从最初的理论摸索到最终的算法落地，离不开多方的专业指导与鼎力支持。

首先，我要向我的指导教师刘树美老师致以最诚挚的谢意。从课题“基于深度强化学习的车联网任务卸载”的初期选定、系统架构的搭建，到深度强化学习算法的代码调试、性能优化，直至论文的反复修改与最终定稿，刘树美老师均倾注了大量的心血，给予了极其专业的学术指导与严格的把关。刘老师严谨治学的学术态度、敏锐前瞻的科研洞察力以及务实求真的工作作风，不仅为我拨开了仿真实验中的诸多技术迷雾，更为我攻克各项技术瓶颈提供了关键启示，是我完成本次毕业设计的核心支撑。

其次，特别致谢《Digital Twin Enabled Task Offloading for IoVs: A Learning-Based Approach》等核心参考文献的作者团队。前沿学者的卓越工作与严谨的系统模型，为本文的 MDP 建模及 PA-A3C 算法的底层逻辑提供了坚实的理论基石与宝贵的研究视角。站在巨人的肩膀上，本研究才得以顺利开展。

同时，向本文在代码复现与仿真实验过程中，所依托的 Python 科学计算生态、PyTorch 深度学习框架等开源工具的开发者的开发者，以及相关参考学术配图、开源资料的所有者表达由衷的敬意。开源社区无私的技术共享，是本文得以高效完成动态网络时序仿真与模型训练的重要保障。

最后，衷心感谢参与本论文评阅与答辩评审的各位专家学者。感谢您在百忙之中对本文的审阅，您的宝贵意见将是我未来继续学术探索与工程实践的重要指引！

参考文献

- [1] Minerva R, Lee G M, Crespi N. Digital twin in the IoT context: A survey on technical features, scenarios, and architectural models[J]. Proceedings of the IEEE, 2020, 108(10): 1785-1824
- [2] Abbas N, Zhang Y, Taherkordi A, et al. Mobile edge computing: A survey[J]. IEEE Internet of Things Journal, 2017, 5(1): 450-465.
- [3] Du J, Yu F R, Chu X, et al. Computation offloading and resource allocation in vehicular networks based on dual-side cost minimization[J]. IEEE Transactions on Vehicular Technology, 2018, 68(2): 1079-1092.
- [4] Guo H, Liu J, Qin H, et al. Collaborative computation offloading for mobile-edge computing over fiber-wireless networks[C]//GLOBECOM 2017-2017 IEEE Global Communications Conference. IEEE, 2017: 1-6.
- [5] Jiang Z, Zhou S, Guo X, et al. Task replication for deadline-constrained vehicular cloud computing: Optimal policy, performance analysis, and implications on road traffic[J]. IEEE Internet of Things Journal, 2017, 5(1): 93-107.
- [6] Zhao L, Zhao Z, Zhang E, et al. A digital twin-assisted intelligent partial offloading approach for vehicular edge computing[J]. IEEE Journal on Selected Areas in Communications, 2023, 41(11): 3386-3400.
- [7] Zeng Y, Tang J. MEC-assisted real-time data acquisition and processing for UAV with general missions[J]. IEEE Transactions on Vehicular Technology, 2022, 72(1): 1058-1072.
- [8] Shah Z, Javed U, Naeem M, et al. Mobile edge computing (MEC)-enabled UAV placement and computation efficiency maximization in disaster scenario[J]. IEEE Transactions on Vehicular Technology, 2023, 72(10): 13406-13416.
- [9] Chen D, Liu Y C, Kim B G, et al. Edge computing resources reservation in vehicular networks: A meta-learning approach[J]. IEEE Transactions on Vehicular Technology, 2020, 69(5): 5634-5646.
- [10] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. nature, 2015, 518(7540): 529-533.
- [11] Zhan W, Luo C, Wang J, et al. Deep-reinforcement-learning-based offloading scheduling for vehicular edge computing[J]. IEEE Internet of Things Journal, 2020, 7(6): 5449-5465.
- [12] Liu K H, Liao W. Intelligent offloading for multi-access edge computing: A new actor-critic approach[C]//ICC 2020-2020 IEEE International Conference on Communications (ICC). IEEE, 2020: 1-6.
- [13] He Y, Zhao N, Yin H. Integrated networking, caching, and computing for connected vehicles: A deep reinforcement learning approach[J]. IEEE transactions on vehicular technology, 2017, 67(1): 44-55.
- [14] Zhou H, Wu T, Zhang H, et al. Incentive-driven deep reinforcement learning for content caching and D2D offloading[J]. IEEE Journal on Selected Areas in Communications, 2021, 39(8): 2445-2460.
- [15] Huang L, Bi S, Zhang Y J A. Deep reinforcement learning for online computation offloading in wireless powered mobile-edge computing networks[J]. IEEE Transactions on Mobile Computing, 2019, 19(11): 2581-2593.
- [16] Zhu X, Luo Y, Liu A, et al. A deep reinforcement learning-based resource management game in vehicular edge computing[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(3): 2422-2433.

- [17] Cheng N, Lyu F, Quan W, et al. Space/aerial-assisted computing offloading for IoT applications: A learning-based approach[J]. *IEEE Journal on Selected Areas in communications*, 2019, 37(5): 1117-1129.
- [18] Zhao N, Ye Z, Pei Y, et al. Multi-agent deep reinforcement learning for task offloading in UAV-assisted mobile edge computing[J]. *IEEE Transactions on Wireless Communications*, 2022, 21(9): 6949-6960.
- [19] Yang Q, Liu Y, Chen T, et al. Federated machine learning: Concept and applications[J]. *ACM Transactions on Intelligent Systems and Technology (TIST)*, 2019, 10(2): 1-19.
- [20] Dai P, Hu K, Wu X, et al. Asynchronous deep reinforcement learning for data-driven task offloading in MEC-empowered vehicular networks[C]//*IEEE INFOCOM 2021-IEEE Conference on Computer Communications*. IEEE, 2021: 1-10.
- [21] Dai Y, Zhao J, Zhang J, et al. Federated deep reinforcement learning for task offloading in digital twin edge networks[J]. *IEEE Transactions on Network Science and Engineering*, 2024, 11(3): 2849-2863.
- [22] Bariah L, Sari H, Debbah M. Digital twin-empowered communications: A new frontier of wireless networks[J]. *IEEE Communications Magazine*, 2023, 61(12): 24-36.
- [23] Zheng J, Zhang Y, Luan T H, et al. Digital twin enabled task offloading for IoVs: A learning-based approach[J]. *IEEE Transactions on Network Science and Engineering*, 2023, 11(1): 659-672.
- [24] Zhang Z, Zhouand H, Zhao L, et al. Digital twin assisted computation offloading and service caching in mobile edge computing[C]//*2022 IEEE 42nd international conference on distributed computing systems (ICDCS)*. IEEE, 2022: 1296-1297.
- [25] Sun W, Zhang H, Wang R, et al. Reducing offloading latency for digital twin edge networks in 6G[J]. *IEEE Transactions on Vehicular Technology*, 2020, 69(10): 12240-12251.
- [26] Liang K, Wang Y, Li Z, et al. Digital twin assisted deep reinforcement learning for computation offloading in AAV systems[J]. *IEEE Transactions on Vehicular Technology*, 2025, 74(5): 8466-8471.
- [27] Kingma D P, Welling M. Auto-encoding variational bayes[J]. *arXiv preprint arXiv:1312.6114*, 2013.
- [28] Hu Q, Cai Y, Yu G, et al. Joint offloading and trajectory design for UAV-enabled mobile edge computing systems[J]. *IEEE Internet of Things Journal*, 2018, 6(2): 1879-1892.
- [29] Li B, Liu Y, Tan L, et al. Digital twin assisted task offloading for aerial edge computing and networks[J]. *IEEE Transactions on Vehicular Technology*, 2022, 71(10): 10863-10877.
- [30] Yuan X, Chen J, Zhang N, et al. Digital twin-driven vehicular task offloading and IRS configuration in the Internet of Vehicles[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(12): 24290-24304.
- [31] Di Renzo M, Zappone A, Debbah M, et al. Smart radio environments empowered by reconfigurable intelligent surfaces: How it works, state of research, and the road ahead[J]. *IEEE journal on selected areas in communications*, 2020, 38(11): 2450-2525.
- [32] Zhang K, Cao J, Maharjan S, et al. Digital twin empowered content caching in social-aware vehicular edge networks[J]. *IEEE Transactions on Computational Social Systems*, 2021, 9(1): 239-251.
- [33] Liao X, Wang Z, Zhao X, et al. Cooperative ramp merging design and field implementation: A digital twin approach based on vehicle-to-cloud communication[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2021, 23(5): 4490-4500.
- [34] Tu Z, Qiao L, Nowak R, et al. Digital twins-based automated pilot for energy-efficiency assessment of intelligent transportation infrastructure[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(11): 22320-22330.

- [35] Hevesli M, Seid A M, Erbad A, et al. Task offloading optimization in digital twin assisted MEC-enabled air-ground IIoT 6G networks[J]. IEEE Transactions on Vehicular Technology, 2024, 73(11): 17527-17542.
- [36] Younan M, Houssein E H, Elhoseny M, et al. Challenges and recommended technologies for the industrial internet of things: A comprehensive review[J]. Measurement, 2020, 151: 107198.
- [37] 谢人超, 廉晓飞, 贾庆民, 等. 移动边缘计算卸载技术综述[J]. 通信学报, 2018, 39(11): 138-155.
- [38] 康宇, 刘雅琼, 赵彤雨, 等. AI 算法在车联网通信与计算中的应用综述[J]. 电信科学, 2023, 39(1): 1-19.
- [39] 孙滔, 周铨, 段晓东, 等. 数字孪生网络(DTN): 概念、架构及关键技术[J]. 自动化学报, 2021, 47(3): 569-582.